三、研究計畫內容（以中文或英文撰寫）：

（一） 撰寫前請先勾選計畫簡述表

1. 申請計畫類別

■類別一-合作型計畫（勾選此項者請回答以下第 2-10 題）

☐類別二-AI 藥物開發計畫（勾選此項者請回答以下第 2-6 題）

☐類別三-AI 軟體技術開發（勾選此項者請回答以下第 7-10 題）

2. 開發藥物領域別

■惡性腫瘤 ☐心血管疾病 ☐腦及神經系統疾病 ☐肺及呼吸道系統疾病

☐代謝相關疾病 ☐免疫相關疾病 ☐消化系統疾病 ☐其他：_____

3. AI 軟體技術應用之藥物研發領域（可複選）

■藥物篩選 ■藥物設計 ■藥物合成 ■ADMET 預測 ■毒性模擬

■臨床驗證預測 ☐其他：_____

4. 是否已有候選藥物?

☐無

■有（請簡述）沈延盛教授團隊先前以 FDA-approved library docking 已找到可能的 PAI-1 antagonist（Gonadorelin 和 Tetrahydrofolic acid）， 並已做胰臟星狀細胞毒性與抑制 PAI-1 促活化的初步驗證。另也設計 PAI-1 mimicking peptides(共有三個候選胜肽 6980、7688、6988)，初步顯示可與 LRP1 結合並被 PAI-1 競爭。

5. 目前開發之藥物是否已與國內外 AI 技術服務提供者或 AI 公司合作?

■無

☐有（若勾選本項目，請說明雙方目前就成果歸屬之協商進度：☐已簽署合約

☐尚未簽署合約 ☐其他，請說明：_____）

6. 對於本計畫是否已規劃所需之 CRO（臨床前委外研究）服務?

☐否

☐是(若勾選本項目，請說明已規劃之 CRO 服務機構/廠商：_____

及是否規劃使用本會補助計畫之 CRO 聯盟服務？☐是 ☐否☐尚未決定)

■尚未決定

☐其他，請說明：_____

7. 欲開發之 AI 軟體技術類型（可複選）

☐分子生成模型 ☐分子特徵預測模型

☐反應路徑與合成規劃 ■蛋白質結構/功能預測 ■生物活性預測模型

■資料標註/資料清整工具 ■高效能運算/平台整合工具

☐其他：_____

8. 資料來源類型（可複選）

■公開資料庫（如 ChEMBL、PubChem、PDB 等）

☐商業授權資料庫（請註明來源）：_____

■醫療院所提供（已完成人體研究/IRB 授權）

■自行產生或模擬資料（如 docking、simulation、生成式模型）

☐與藥物研發團隊合作（若勾選本項目，請一併提供合約）

☐已完成必要授權，可合法使用於模型訓練

☐其他：_____

9. 資料品質與處理方式（可複選）

■資料量充足，可支援模型訓練

☐需進行資料清理（duplicate removal / normalization）

☐需進行資料標註或結構化

☐需進行資料補強/生成增強（data augmentation）

☐計畫期間需建立資料管理流程（metadata、versioning）

☐已完成資料品質評估（如 noise rate、missing data 分析）

10. 目前開發之 AI 軟體技術是否已與國內外藥物開發團隊合作?

■無

☐有（若勾選本項目，請說明雙方目前就成果歸屬之協商進度：☐已簽署合約 ☐尚未簽署合約 ☐其他，請說明：_____）

（二） 請詳述本研究計畫所要探討或解決的問題、研究原創性、重要性、預期影響性、AI 技術應用於藥物研發之國內外研究現況、AI 技術應用於藥物開發之階段(藥物設計、ADMET 預測或其他)及應用之軟體、專利佈局、未來商業模式與價值以及國際發展趨勢與策略佈局、重要參考文獻之評述等。

一、癌症治療的臨床困境與藥物開發策略方法之困難

根據衛生福利部於 2025 年 6 月公布之統計資料，癌症已連續 43 年位居我國十大死因之首，全年死亡人數達 54,032 人，約佔總死亡人數之 26.8% [1, 2]。在臨床實務上，由於多數癌症於早期階段症狀不明顯，且現行篩檢工具仍具侷限性，導致相當比例之病患於確診時已屬疾病晚期，使治療成效與整體存活率受到顯著限制。

目前新藥開發流程高度仰賴動物模型評估療效與安全性，然而，受限於物種間生理特性與分子調控機制差異，許多在體外系統或動物實驗中具潛力候選藥物，於臨床試驗階段往往無法重現其預期療效，導致臨床轉譯失敗率居高不下。此一現況顯示，建立以人類真實世界資料（Real-World Data, RWD）為核心藥物開發策略，已成為當前精準醫療與新藥研發中迫切且關鍵研究方向。

為回應上述挑戰，本系統於子計畫 1 中整合本土大規模（N > 1,000）之臨床資料與多體學資料，建構可供人工智慧模型學習之「人類疾病模型」，以奠定精準族群分層與治療策略優化之實證基礎。透過子計畫 1 所建立標準化事實層（Facts Layer），可系統性彙整人口學特徵、治療線反應與存活結果等關鍵資訊，並統一資料結構與格式，作為後續 AI 模型分析與推論之核心資料基礎。

此一「人類資料優先（Human-data-first）」研究模式，有助於降低過度仰賴體外實驗與動物模型所導致臨床轉譯落差，提升候選藥物與實際臨床需求契合度，進而強化我國在精準醫療與創新藥物研發領域研究能量與國際競爭力。

二、現行多體學與人工智慧藥物開發的發展現況與關鍵落差

過去十餘年間，雖已有 The Cancer Genome Atlas（TCGA）、International Cancer Genome Consortium（ICGC）等[40, 41]大型多體學研究計畫，系統性描繪癌症分子異質性，惟其研究設計多屬橫斷式分析，普遍缺乏病患縱向治療歷程、用藥反應與安全性等關鍵臨床資訊，因而限制其在藥物開發與臨床決策層面的直接應用價值。

另一方面，近年興起多數 AI 藥物開發平台（例如：Exscientia、Insilico Medicine）主要聚焦於分子生成、虛擬篩選與結構優化等早期研發階段，但普遍缺乏與人類 RWD 的直接連結，使其難以支援具臨床可解釋性與決策意義之「虛擬臨床試驗（In silico clinical trials）」分析。此一「從

人類資料到決策」的斷裂，使 AI 模型所提出之候選藥物難以有效銜接後續 Pre-Investigational New Drug（pre-IND）評估流程與臨床轉譯需求，亦凸顯建立端到端、臨床導向的新藥研發架構迫切性。

三、本計畫之整體研究構想與系統架構

為回應上述臨床與研發瓶頸，本計畫提出一套以「人類資料優先（Human-data-first）」與「以病人為中心（Patient-centric）」為核心的端到端 AI 新藥研發平台，目標在於填補「從人類資料到 pre-IND 決策」之結構性缺口，並以四個相互銜接核心子計畫 1–4 形成臨床導向的研發流程。

1. **子計畫 1：人類疾病模型與事實層建置**
   整合本土大規模（N > 1,000）臨床資料與多體學資料，建立可供 AI 學習之「人類疾病模型」，並透過標準化事實層（Facts Layer）系統性彙整人口學特徵、治療線反應、存活結果等關鍵資訊，統一資料結構與格式，作為後續推論與決策基礎。
2. **子計畫 2：Council of Agents（虛擬委員會）決策推論**
   以多代理協作架構模擬真實專家委員會的推論流程，將異質資料庫轉化為可呼叫 Application Programming Interface（API）模組，使系統得以整合多來源證據、推論過程追溯，以及信心量化，緩解傳統 AI 預測在醫療應用中常見的黑盒子問題。
3. **子計畫 3：候選藥物之生成式設計與物理導向優化**
   針對蛋白質候選藥物結構性組成，結合生成式設計與物理導向動力學，解析標靶結構表面關鍵作用熱點（Hot spots），設計具提升藥效並降低不良反應潛力之分子變體，從結構層次提升藥物於腫瘤組織中的穿透性與治療效果。
4. **子計畫 4：風險分層與虛擬臨床介入模擬**
   結合 Physiologically based pharmacokinetic（PBPK）與 Quantitative systems pharmacology（QSP）等機制模型 In silico 預測候選藥物於人體腫瘤組織內的動態濃度變化並量化其病徵抑制效果，以於臨床前階段辨識潛在安全性風險、支持族群分層與試驗設計決策，降低後續開發不確定性。

四、研究原創性

本計畫原創性體現在首創一套「以病人為中心（Patient-centric）」的端到端 AI 新藥平台，而非傳統以化合物為核心的研發架構。系統具備四項原創特徵：

1. **子計畫 1 建立首座多模態人類資料事實層**，涵蓋治療線、血栓風險與腫瘤微環境特徵，形成可供 AI 學習與臨床驗證的資料基底。
2. **子計畫 2 採多代理協作（Multi-Agent）架構**，以 Toolformer 概念，將 Ensembl、DrugBank 等異質資料庫工具化，實現結構化證據蒐集與具可解釋性的信心評分 [3, 44, 43]。
3. **子計畫 3 提出 PSOS（Prefix-Scan Online Softmax）演算法**，在維持 **Single-Precision Floating-Point**（FP32）高精度前提下，改善長序列蛋白質計算瓶頸，支援高效率多目標最佳化。
4. **子計畫 4 整合 PBPK/QSP 機制模擬與因果推論**，搭配 AI 模仿臨床專家決策流程，智慧調用 PBPK/QSP 工具，並以貝氏校準技術結合成大沈延盛醫師團隊臨床世代資料優化模型，建立具臨床預測意義之數位孿生（Digital Twin）平台 [46, 47]。

五、研究重要性

本計畫以「虛擬臨床試驗（In silico clinical trials）」作為核心方法論，建構一套由人類資料驅動之資料導向決策流程，使藥物研發與試驗設計得以由傳統經驗導向，轉向可重現、可驗證且具族群分層能力的系統化推論機制。透過於前臨床階段即整合多體學與臨床資料，本系統可模擬不同族群在療效與安全性上的反應差異，並提前評估潛在排除條件，從而降低臨床試驗失敗風險與整體研發成本，補足我國在「從人類資料到 pre-IND」臨床轉譯鏈結上的結構性缺口。基於上述平

台架構，本計畫選擇胰臟導管腺癌（Pancreatic Ductal Adenocarcinoma , PDAC）作為先驅驗證案例，聚焦其治療長期失敗的關鍵主因：腫瘤纖維化（Fibrosis），並系統性建構 PAI-1/LRP1 相關之人類證據鏈。值得注意的是，該證據鏈不僅適用於胰臟癌，亦具跨癌症類別與跨疾病之「泛纖維化（Pan-fibrotic）」治療潛力，可延伸應用至肺纖維化、肝纖維化等高度未被滿足的醫療領域。整體而言，本計畫所提出之 AI 驅動藥物研發與虛擬臨床試驗方法論，將有助於強化台灣在精準醫療與創新藥物研發領域的策略能量，並提升其國際競爭地位。

六、研究預期影響性

1. **短期影響：**完成胰臟癌多模態人類資料事實層建置，並評估 PAI-1 抑制分子系統性 ADMET（Absorption, Distribution, Metabolism, Excretion, Toxicity）（吸收、分布、代謝、排除與毒性）與可開發性（Developability Index），建立具科學依據之 Go/No-Go 決策工具。
2. **中期影響：**產出具備商業授權潛力之先導藥物（Lead Candidates），並透過虛擬臨床試驗平台模擬最佳劑量區間、收案條件與主要療效指標，為 Phase I/II 試驗設計提供客觀且可量化決策支持。
3. **長期影響：**建立台灣首座完整之「癌症 AI 藥物開發平台」，並將胰臟癌之研發模式延伸至泛纖維化腫瘤（Pan-fibrotic oncology）及相關慢性纖維化疾病，形成可持續運作的新藥研發生態系。最終透過 SaaS（Software as a Service）授權與共同開發模式吸引國際藥廠合作，提升台灣於智慧新藥研發領域國際能見度。並使此癌症藥物開發模式系統性擴展至其他癌症。

七、AI 技術應用於藥物開發之階段與軟體（AI Methods & Tools）

本系統由四個核心子計畫構成，其對應之分析方法與工具鏈如下：

1. **子計畫 1（多體學標準化分析）：** 採用 Seurat、PLINK、DESeq2、MaxQuant 建立標準化 Facts Layer [48, 49, 50, 51]。
2. **子計畫 2（信心決策 Agent）：** 實作 Toolformer 架構 API （例如： Ensembl、DrugBank、ChEMBL）蒐集自動化證據、整合與推論信心量化 [3, 44, 43]。
3. **子計畫 3（分子優化 Agent）：**採用 PSOS 演算法，結合 AlphaFold、AutoDock Vina、Chemistry at HARvard Macromolecular Mechanics, CHARMM）最佳化 AI–Physics 混合 [23, 25, 26]。
4. **子計畫 4（虛擬臨床介入 Agent）：**整合 PK-Sim®（PBPK）與 MoBi®（QSP）模擬引擎，並以因果森林（Causal Forest）執行族群分層與介入效果評估，所有工具（PBPK, QSP, etc.）調用以及聯絡其他子計畫 Agents 時機選擇，皆透過改良監督式強化學習（Supervised Reinforcement Learning, SRL）方法，逐步學習專家決策流程，達到精準且即時的智能決策流 [10, 46, 47]。

八、智財佈局與商業模式

本計畫的智慧財產權策略，旨在為這個整合性 AI 決策平台建立一個多層次、立體化的智慧財產權組合，其核心思想是從保護「什麼」（What -藥物分子），擴展到保護「如何」（How-決策方法）與「為何」（Why -數據洞見）。此策略參照國際頂尖 AI 藥物開發公司（例如：Exscientia 與 BenevolentAI 的佈局邏輯，但更強調本平台獨有的系統整合性與數據優勢 [10, 12]。

（一） 專利佈局（IP Strategy）

本計畫的智慧財產權策略，旨在保護一個整合性的 AI 決策平台系統，而非僅限於單一藥物分子。根據美國專利商標局 2025 年 11 月發布的「AI 輔助發明專利審查指南」，本計劃的專利佈局策略採用四層防禦式專利佈局策略[12]：

1. 系統與方法專利

此為平台最核心的專利護城河。本計畫將申請三項關鍵方法專利：

(1) 多代理人協作決策方法（子計畫 2）：保護將多源異構數據轉化為標準化「計算證據」，並由具不同專業領域的 AI 代理人協作、可解釋性推理的創新方法。此方法論超越傳統黑盒子模型，提供完整推理軌跡與信心評分。

(2) 物理導向的藥物生成方法（子計畫 3）：保護結合生物物理約束與生成式 AI 的胜肽設計方法，特別是將 Alanine Scanning 等濕實驗數據作為約束指導化學空間探索的獨特流程。同時保護為解決長序列蛋白質計算瓶頸而開發的 PSOS(Prefix-Scan Online Softmax）演算法。

(3) 數位孿生與虛擬臨床試驗方法（子計畫 4）：保護整合 PBPK/QSP 模型與因果推論 [46, 47]，利用台灣本土臨床數據進行貝氏校準的虛擬臨床試驗系統。根據 FDA 最新指南，此類經充分驗證的計算模型與模擬（Computational Modeling and Simulation, CM&S）證據，正逐漸被接受用於支持藥物開發與監管審查 [14]。

2. 營業秘密

(1) 標準化臨床事實層：基於台灣大規模臨床世代（N>1,000）與多體學數據建構的「人類疾病模型」，其數據綱要、註解標準、處理流程，以及台灣族群特異性的生物學洞見，是國際通用模型無法複製的獨特資產，將以最嚴格的營業秘密保護。

(2) AI 模型權重與專有知識庫：所有訓練完成的 AI 模型權重與平台運作中積累的隱性知識，包括成功的藥物設計規則與失敗的實驗數據，作為核心營業秘密。

3. 核心藥物專利

針對平台發現的高價值候選藥物，申請物質組成專利(Composition-of-Matter Patents）與醫療用途專利（Method-of-Use Patents），確保單一產品的市場獨佔性。

4. 軟體著作權

登記平台的軟體程式碼、使用者介面與數據庫結構設計，並透過合作協議明確數據庫權利歸屬。

（二） 未來商業模式與價值

本計畫的商業模式發揮其作為「學術研究工具」與「商業化決策平台」的雙重身份，建立從學術生態汲取創新養分、在商業應用中實現價值最大化的正向循環。核心價值主張是：透過整合台灣獨有臨床數據與系統化 AI 決策的端到端平台，顯著降低早期藥物開發的失敗風險，為國際藥廠進入亞洲市場提供無可替代的族群特異性決策支援。本計畫的商業模式參照國際頂尖 AI 藥物平台公司（Insilico Medicine、Exscientia）的成功演進路徑，規劃為三階段實現 [14, 15]：

1. 第一階段：學術賦能與生態圈建立（第 1-2 年）

定位為台灣乃至亞太地區領先的「臨床轉譯研究基礎設施」。

(1) 商業模式：平台即服務（Platform as a Service, PaaS），將平台核心模組（子計畫 1 的數據整合與子計畫 2 的靶點探索）以 SaaS 形式提供給頂尖大學、醫學中心與研究機構，採機構年度訂閱制。

(2) 價值主張：為學術研究者提供強大 AI 工具，加速研究成果的轉譯潛力評估。透過學術合作持續獲取最新研究回饋與高品質數據，優化平台演算法，形成正向循環。

2. 第二階段：產業賦能與戰略合作（第 2-4 年）

定位為「商業級臨床前決策支援平台」。

(1) 商業模式：戰略研究合作，與國內外大型製藥公司及生技公司建立深度合作，涵蓋靶點授權與端到端研發服務。

(2) 國際對標：Exscientia 與 Sanofi 的 2022 年合作案提供重要參考。該協議涵蓋最多 15 個候選藥物，包括 1 億美元前期付款與高達 52 億美元里程碑付款 [14]。本計畫基於台灣臨床數據的「數位孿生」模型（子計畫 4），能為進入亞洲市場的國際藥廠提供族群特異性療效與安全性預測，這是相較於國際競爭對手獨一無二的商業利基。

3. 第三階段：高價值資產孵化與價值最大化（第 4 年以後）

當平台運作成熟並自主產生高潛力候選藥物後，進入價值實現的最高級階段。

(1) 商業模式：候選藥物對外授權（Out-Licensing）與新創公司孵化（NewCo Spin-off）。將完成臨床前開發的候選藥物授權給大型藥廠，或聯合創投基金成立獨立子公司專注後續開發。

(2) 國際對標：此模式複製 Insilico Medicine 的成功路徑。Insilico 透過與大藥廠的合作驗證平台價值後，近年投入自主藥物 Pipeline 開發，其首個 AI 發現的藥物已於 2025 年獲 Food and Drug Administration（FDA）批准進入臨床試驗（IND），公司總融資額已超過 5 億美元 [15]。這證明「服務+自主研發」的混合模式是實現平台價值最大化的最優路徑。

九、國際發展趨勢與策略佈局

（一）產業典範轉移：從「生成式 AI」邁向「具備臨床推理能力的端到端代理人」

全球 AI 藥物開發正經歷第三波典範轉移。第一波是以 AlphaFold 為代表的結構預測 [23]；第二波是以 Insilico Medicine 為首的生成式 AI，其核心技術已驗證快速生成分子的能力。然而，目前的第三波趨勢——「代理人化全自動平台（Agentic AI）」——正試圖解決更複雜的「跨階段決策」與「臨床轉譯」問題。

目前的國際競爭版圖可分為四大陣營，而本計畫針對現有競品在「精準醫療落地」與「法規監管適配」上的缺口（The Calibration & Explainability Gaps），提出具備差異化的戰略解方：

1. 陣營 A：端到端代理人（例如：Prompt-to-Pill）

(1) 現況： 學術界已證明 Large Language Model（LLM）可串聯「檢索-設計-模擬」流程。

(2) 缺點（The Reasoning Gap）：通用 LLM 缺乏「事實接地（Grounding）」，容易產生生化性質不合理或脫離臨床現實的幻覺，且多採用線性任務分派，缺乏高階臨床辯證思維。

(3) 本計畫優勢（子計劃 1+4）：本計畫不只依賴 LLM，子計劃 1 建立標準化的「多體學事實層（Facts Layer）」，強制 Agent 的推論必須基於清洗過的 PAI-1 臨床數據。此外，子計劃 4 的 **Supervised Reinforcement Learning** （SRL）中樞確保決策邏輯符合臨床黃金標準，而非單純的文字生成。

2. 陣營 B：生成式藥物發現（例如：Insilico Medicine）

(1) 現況：擅長靶點發現與小分子生成（Generative Chemistry），已有藥物進入臨床。

(2) 缺點（The Calibration Gap）：其強項在於「化學」與「實驗室自動化」，但在「虛擬病患模擬」上多依賴歐美公開資料庫（例如：UK Biobank），缺乏針對亞裔族群特異性（例如：胰臟癌高致死率特徵）的深度臨床表型校準及因果推論機制。

(3) 本計畫優勢（子計劃 2+4）：本計畫不僅生成分子，更生成「臨床證據」。透過子計劃 2 的「專家委員會」、「可解釋信心評分」與子計劃 4 的「因果數位孿生」，能預

測藥物在台灣/亞裔族群中的異質性反應（例如：出血副作用），解決國際大廠模型在跨族群轉譯上的盲點。

3. **陣營 C：虛擬臨床試驗（例如：Unlearn.AI、Novadiscovery）**
   (1) **現況：**專注於利用數位孿生（Digital Twins）或 QSP 模型縮減對照組規模。
   (2) **缺點（The Explainability Gap）：**這些平台通常是「下游工具」，缺乏與「上游藥物設計」的閉環連動，其模型多訓練於歐美數據 The Cancer Genome Atlas（TCGA）、UK Biobank）[40]，且多為「黑盒子」，缺乏符合醫療法規 Taiwan Food and Drug Administration（TFDA）、Food and Drug Administration（FDA）、Software as a Medical Device（SaMD）要求的可解釋性證據鏈。
   (3) **本計畫優勢（子計劃 3+4 閉環）：**本計畫實現真正的「設計-模擬閉環」，子計劃 4 的臨床模擬結果（例如：組織暴露量不足）會直接轉化為子計劃 3 的 Reward/Loss 訊號，驅動 Designer Agent 修改胜肽結構（例如：修飾 C 端），加上 NCKU 獨家的 PAI-1 世代數據校準，形成數據護城河。
4. **陣營 D：自主科學家（例如：Sakana AI）**
   (1) **現況：**展示 AI 自主閱讀文獻、生成科學假說的能力。
   (2) **缺點：**屬於「通用型（Generalist）」代理人，缺乏特定疾病領域的深度專家知識（Domain Expertise）與底層運算效率優化。

（二）**本計畫優勢（SRL on Expert Trajectories）：**本計畫的 Agent 是「專科醫師」，透過 SRL（監督式強化學習）技術，模型直接學習沈延盛醫師等臨床專家的決策軌跡，使其具備針對胰臟癌複雜情境的判斷力，且透過自主研發**局部** PSOS 加速整體運算效率。為了構建全球首個「具備外科醫師思維」且「符合運算主權」的 AI 藥物開發中樞，本計畫採取「深而精」的策略，整合以下四大核心技術：

1. **基於 ICLR 2026 之 SRL 與工具調用融合（從 Expert Trajectories 到 Step-wise Reasoning）**

   本計畫子計劃 4 採用改良自 Deng, Y., et al. (ICLR 2026)的 **SRL** 架構，有別於傳統 Supervised Fine-Tuning（SFT）僅學習最終處方，SRL 訓練 Orchestrator 在每一步行動之前，生成 **Internal Monologue（<think> tag）**，模擬專家的思考過程（例如：「病患血小板較低，雖然 PAI-1 抑制劑有效，但我應先確認凝血功能影響……」）。同時，透過 Dense Reward Signal，模型將學會一套「黃金標準（Golden Standards）」的操作序列，精準調用 PBPK 與 QSP 工具。

2. **導入「專家委員會（Council of Agents）」之多觀點協作機制（子計劃 2）**

   針對候選藥物的優化決策，本計畫子計劃 2 超越傳統單一模型的評分機制，構建具備不同專業角色的「多代理人委員會」。

   (1) **對抗式辯論（Adversarial Debate）：**系統包含「藥物化學家 Agent」（關注親和力）、「結構生物學家 Agent」（關注結合位點）與「臨床毒理學家 Agent」（關注副作用）。
   (2) **決策優化：**透過 Agent 之間的交互詰問與投票機制，模擬真實研發團隊的會議決策，能有效避免單一模型陷入局部最佳解（Local Optima），顯著提升候選藥物的臨床成功率。

3. **建立「證據鏈思考（Chain-of-Evidence）」機制以符合法規要求（子計劃 4）**

   為解決 AI 的「黑盒子」問題，本計畫子計劃 4 獨創「證據鏈思考」機制。

   (1) **Reasoning Logs（推論日誌）：**要求每一項藥物設計與虛擬試驗決策，都必須附上完整的推論日誌，詳細記載引用的多體學證據來源及因果推論權重。

(2) **情境化校準（Contextual Calibration）**：所有推論均需針對 **NCKU PAI-1 臨床數據**校準，這是本計畫最強大的數據護城河，意味著本計畫的 AI 是專為**台灣/亞裔基因型**訓練的，能精準預測該族群對 PAI-1 療法特有的副作用。此機制不僅消除 AI 幻覺，更直接對接 TFDA/FDA 對於 AI 醫療器材（SaMD）日益嚴格的「可解釋性」與「可驗證性」標準。

4. 演算法自主權與運算突破：自主研發局部 PSOS 演算法（子計劃 3）

針對長序列生物資訊（如複雜蛋白質複合物或全基因組）的運算瓶頸，本計畫子計劃 3 自主研發**局部 PSOS（Prefix-Scan Online Softmax）演算法**。

(1) **技術突破**：解決現有 Transformer 架構在處理長序列時的 Context Window 限制與記憶體瓶頸。

(2) **全精度推論**：確保在處理複雜結構時能維持全精度（FP32）推論，不因效率犧牲準確度。這確立我國在底層 AI 演算法上的**技術主權**，確保平台不僅在應用層領先，在基礎運算層亦具備國際競爭力。

十、重要參考文獻之評述

1. **Deng, Y., et al. (2026). "Supervised Reinforcement Learning: From Expert Trajectories to Step-wise Reasoning." International Conference on Learning Representations (ICLR). [9]**
   - **評述**：此文獻為本計畫子計畫 4 核心演算法的理論基礎，該研究提出一種結合 SFT 與 RL 的新框架（SRL)，透過將複雜問題拆解為「步驟化行動」並給予密集獎勵，成功讓模型學會複雜的推理能力。本計畫將此方法論移植至「臨床轉譯推理」，利用成大專家的決策軌跡作為 Ground Truth，訓練 AI 在調用 PBPK/QSP 工具時，具備專家級的邏輯判斷力。
2. **Xu, Z., et al. (2025). "A generative AI-discovered TNIK inhibitor for idiopathic pulmonary fibrosis: a randomized phase 2a trial." Nature Medicine, 31, 2602–2610, 2025. [10]**
   - **評述**：此論文是 Insilico Medicine 的核心技術展示，驗證生成式 AI 在靶點發現與結構設計的成熟度。本計畫以此為標竿，但針對其缺乏「族群特異性因果模擬」的缺口，引入子計畫 4 的數位孿生技術與台灣在地數據校準，旨在解決該團隊尚未完全克服的「異質性族群轉譯」難題。
3. **Wang, H., et al. (Vichentijevikj, I., et al.) (2024). "Prompt-to-Pill: End-to-End Drug Discovery with Generative AI Agents.", Bioinformatics Advances, 6(1), 2026, vbaf323. [11]**
   - **評述**：此文獻驗證利用多代理人系統串聯藥物開發全流程的可行性，是 Agentic Workflow 的重要里程碑。然而，該框架主要依賴通用 LLM，缺乏嚴謹的「多體學事實層」，容易產生幻覺。本計畫引入子計畫 1 的標準化證據層與子計畫 4 的證據鏈思考（Chain-of-Evidence）機制，正是為了修正其缺乏物理與臨床準確度的核心缺陷。
4. **Boiko, D. A., et al. (2023). "Emergent autonomous scientific research capabilities of large language models." Nature. [12]**
   - **評述**：本研究指出 AI 已具備規劃複雜實驗與編寫程式碼的潛力，支持本計畫採用「智慧協作中樞」的可行性。然而，該研究亦點出 AI Agent 在處理長序列數據時面臨計算資源與上下文視窗的瓶頸。本計畫針對此未解難題，提出 PSOS（Prefix-Scan Online Softmax）演算法（子計畫 3），在演算法層面上實現對現有文獻技術限制的重要突破。
5. **Lu, C., et al. (Sakana AI). (2024). "The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery." arXiv. [14]**

- **評述**：Sakana AI 展示 AI 自主進行科學發現的潛力，本計畫借鑑其自主性概念，但將其應用範圍收斂至「癌症精準醫療」，並引入**子計畫 2 的「專家委員會（Council of Agents）」**架構進行對抗式辯論，利用 NCKU 臨床規範對其約束，確保其發現具有臨床落地價值。

6. **Fisher, A., et al. (Unlearn.AI). (2023). "Digital Twins for Clinical Trials: A Personalized Baseline Approach." Clinical Trials. [14]**
   - **評述**：Unlearn.AI 是虛擬臨床試驗的技術領先者，本計畫子計畫 4 汲取其統計建模優勢，並進一步融合 QSP 機制性模擬，在台灣 PAI-1 數據上建立更精細的因果數位孿生，填補國際模型在亞裔族群預測上的空白。

（三）填列研究方法、進行步驟及執行進度。請列述下列項目：1.本計畫採用之研究方法與原因及其創新性。2.預計可能遭遇之困難及解決途徑。3.請預估技術發展可進入 IND 申請準備之時程。4.如為須赴國外或大陸地區研究，請詳述其必要性以及預期效益等。

一、系統介紹

本計畫建構之「多模態證據驅動的多代理 AI 藥物篩選決策與虛擬臨床試驗平台」，是一套整合臨床大數據、多體學分析、蛋白質藥物設計與生理機制模擬的整合型系統。本計畫之研究目的為加速傳統開發藥物流程，在傳統藥物開發中，往往依賴大量的人力找尋適合的基因位點，由找尋出的基因位點模擬並設計可行藥物，再驗證適用性與毒性後才能投入臨床試驗，每一步驟都相當的花費時間與人力，導致開發新藥物的時程被拉的極長。

為解決藥物開發人力與時間痛點，本系統將設計四個相對應並極具專業化的核心平台、代理人與模組，用以達成自動化資料蒐集與處理、結合人工智慧利用現有文獻與證據評估藥物可行性與信心指數、以人工智慧模型生成與調整可行藥物結構、自動化毒性驗證與模擬與虛擬臨床試驗等步驟。本計畫首先聚焦於**胰臟癌 PAI-1/LRP1 訊息軸**，以其作為首要示範標靶，並以現有已開發可行藥物為主軸，在設計模型同時，結合生醫團隊對該藥物分析真實藥化性質、毒性分析與臨床實驗數據，藉以驗證此系統有效性。

本計畫預計於兩年內建立模型雛型，結合所有必要資訊，以取得最基本成效，並同時取得生醫團隊相關臨床數據，用以驗證所開發系統有效性，同時作為後續兩年的優化標的。計畫的後面兩年，將持續優化已開發模型，同時結合更多的多體學以及生物相關知識，使模型具備更專業能力，提升整體系統開發藥物的有效性。圖一為本計畫所提出之平台架構整體圖：

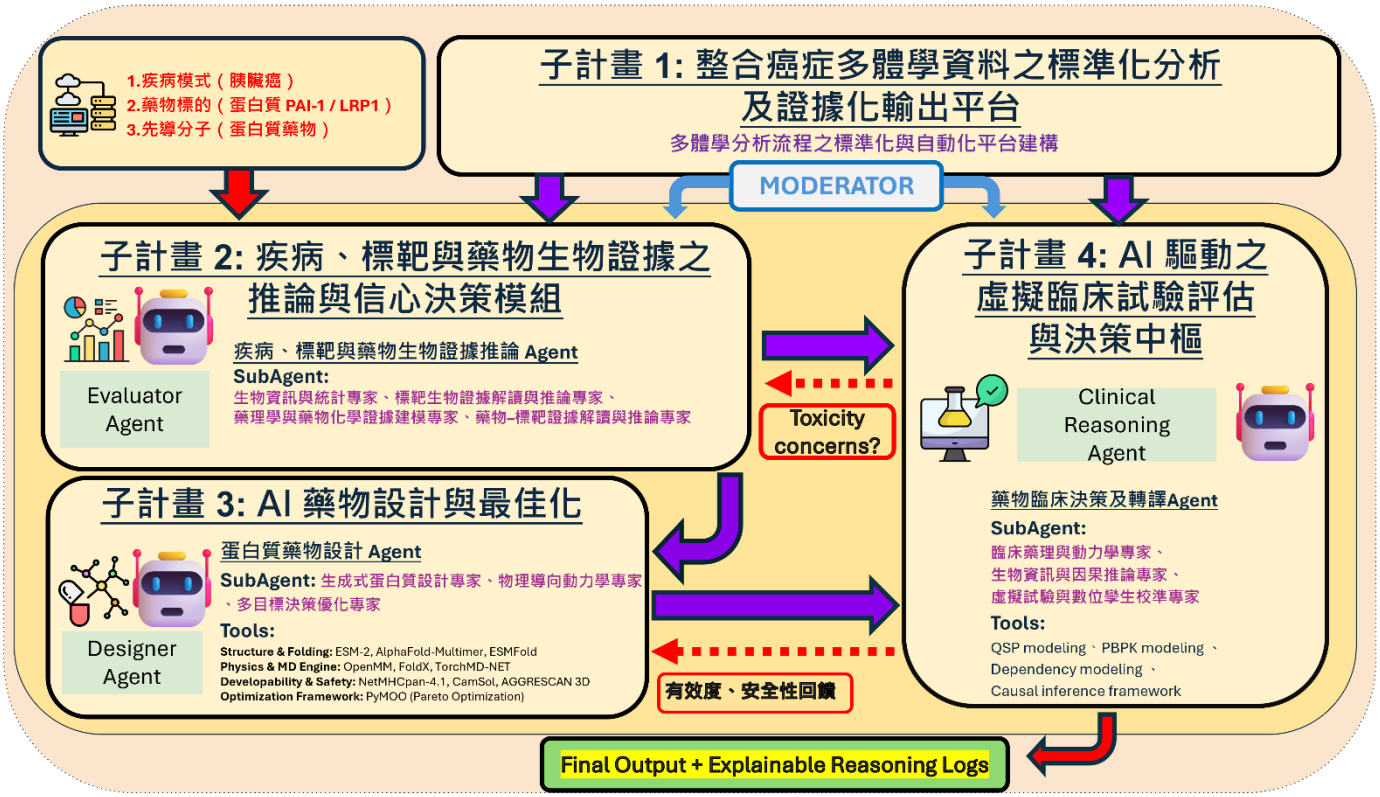

圖一、多模態證據驅動的多代理 AI 藥物篩選決策與虛擬臨床試驗平台架構圖

（一）子計畫 1：整合癌症多體學資料之標準化分析及證據化輸出建構平台

本計畫建構出整個系統的資料來源，研究目的為將消化道癌症生醫資料庫與台灣上消化道癌症臨床試驗聯盟的大規模（N > 1000）臨床 RWD 與多模態體學資料標準化轉型。具體可分為以下內容：

1. **數據標準化與自動化分析流程：**系統開發七大分析平台，涵蓋共通資料標準化、Single Nucleotide Polymorphism（SNP）、Genome-Wide Association Study（GWAS）、Post-GWAS、全外顯子定序（Whole Exome Sequencing, WES）、單細胞 RNA 定序（Single-cell RNA sequencing, scRNA-seq）、Bulk RNA sequencing（Bulk RNA-seq）與蛋白質體學。其核心價值在於將異質、不一致的原始定序或質譜資料，轉換為 AI 模型可直接讀取的「可計算證據包」。
2. **跨模態整合與表型對齊：**子計畫 1 建立以病人為核心的縱向資料結構，將臨床特徵（分期、存活、血栓風險）與分子訊號（基因變異、細胞溝通網路、Protein-protein Interaction（PPI）模組精確對齊），產出多層次的癌症證據圖譜。這確保後續 AI 推論是建立在真實世界的人類疾病模型上，而非僅依賴不可靠的動物模型。

透過以上系統與平台建立，可確立以下子計畫資料來源皆具有可信力與兼容性。

（二）子計畫 2：疾病、標靶與藥物生物證據之推論與信心決策模組

本計畫用以作為對已開發藥物的信心指數，透過利用多代理人協作框架，並將各代理人訓練為具備藥化知識、毒性知識、多體學生物知識的各領域專家，並透過虛擬委員會（Council of Agents）架構，充分討論目標藥物特性，深度推理標靶與藥物的關聯性與信心量化。其具體可分為以下內容說明：

1. **生物醫學資料庫工具化（Database Toolification）：**借鑑 Toolformer 與 GeneGPT 的概念 [3, 4]，本子計畫實作自動化 API 調用工具，能即時查詢 Ensembl、ChEMBL、DrugBank

與 PubMed 等國際權威資料庫[44, 45, 43]。這使得 AI 代理人（Agents）不再只是通用的文本生成，而是具備精確資料存取能力的專業人員。

2. **階層式信心評分系統（TBCI）：**子計畫內的生物資訊與藥理學專家子代理會根據 GWAS 顯著性、Genotype-Tissue Expression（GTEx）組織特異性與 Clinical Variation（ClinVar）致病變異等維度，計算**綜合生物信心指數（Total Biological Confidence Index）**。系統引入「一致性獎勵」與「風險懲罰」機制，自動標註跨體學衝突或跨族群偏差風險，確保決策的透明度與科學嚴謹性。

（三）子計畫 3：AI 藥物設計與最佳化——以 PAI-1 之胜肽先導分子為主案例

本子計畫為專注於最佳化設計**對應目標標靶的胜肽先導分子**。其具體可利用以下方式實現：

1. **AI-Physics 混合最佳化流程：**系統支持胜肽設計路徑，透過丙氨酸掃描(Alanine scanning)、互作指紋分析（Protein-Ligand Interaction Profiler, PLIF）與半柔性對接（Semi-flexible Docking），界定候選分子的關鍵殘基與可修飾位置（Modifiable Sites List）。
2. **PSOS 高精度運算演算法：**針對胜肽長序列計算與多模態證據拼接帶來的運算瓶頸，本子計畫提出 **PSOS（Prefix-Scan Online Softmax）**演算法。該技術能在維持 **FP32 全精度**（這對生醫能量計算至關重要）的前提下，實現線性記憶體增長與高吞吐量推論，解決傳統 FlashAttention 在科學計算中可能產生的數值敏感性問題。
3. **去風險設計（De-risking）：**系統整合 ADMETlab 2.0 與 NetMHCpan，在設計階段即同步評估吸收、分布、毒性、免疫原性與聚集風險，產出具備「設計理由」的可解釋決策報告。

（四）子計畫 4：AI 驅動之虛擬臨床試驗評估與決策中樞

本子計畫為此系統的最核心模組，結合前述子計畫所提供優化後胜肽藥物與藥物信心指數，**進行具備臨床推理能力的**虛擬臨床試驗（In Silico Clinical Trials），整體架構可分為以下幾個部分：

1. **數位孿生（Digital Twin）與校準：**採用 **NVIDIA Nemotron-3-Nano [6]**作為協調者（Orchestrator），引領三個專業子代理。其中，PBPK（生理藥動）代理利用 PK-Sim®模擬腫瘤組織內的藥物濃度曲線；QSP 代理（系統藥理）則以 MoBi®模擬 PAI-1/LRP1 訊息軸的抑制動態；因果分層代理則利用沈延盛醫師團隊的在地化臨床數據進行**貝氏校準**，精確預測台灣族群的治療效應。
2. **SRL 專家軌跡學習與逐步推理：**運用監督式強化學習（SRL）將 NCKU 臨床專家決策歷程轉化為訓練數據，不同於僅學習結果的傳統 SFT 及 RL，Orchestrator 透過生成內部獨白(Internal Monologue)模擬專家思考過程，並利用密集獎勵訊號(Dense Reward Signal)建立工具調用的「黃金標準」，在特定情境下精準協調 PBPK、QSP、FDA/TFDA 資料庫與 ADMET-AI，搭配各子代理人生成深度洞見，進行符合臨床邏輯的輔助決策。
3. **決策回饋與閉環優化：**子計畫 4 會產出包含收案標準與劑量建議的「轉譯決策報告」，並將結構或劑量的優化提示（Hints）回饋至子計畫 3，驅使生成模型重新微調分子，形成一套不斷自我完善的開發閉環。

二、系統整合與工程基礎建設

為確保整體系統的可維運性，本計畫以 **k3s 容器化叢集**與 **n8n 工作流程編排**為基礎，實現跨子計畫的資料調度與任務監控。這種「以病人為中心（Patient-centric）」而非單純「以化合物為中心」的架構，使得台灣能在 AI 驅動的精準醫療競逐中，建立具備在地臨床數據支持的核心示範平台。

以下將針對各子計畫詳細地介紹內容：

子計畫 1：整合癌症多體學資料之標準化分析及證據化輸出建構平台

一、研究目的

癌症精準藥物開發必須同時整合臨床表型與多體學證據（GWAS/WES、Bulk RNA-seq、scRNA-seq、proteome 等），但現有資料常面臨來源分散、格式異質、表型定義不一致與分析流程缺乏標準化等問題，導致跨研究結果難以重現與比較，也難以直接輸入自動化分析流程或 AI 推論模型。即使各體學分析可各自產出統計結果，若缺乏一致的輸出 schema、版本控管、證據追溯與工作流程管理，整體系統仍將高度依賴個別研究者經驗與手工整合，無法擴展至多專案、多使用者或長期持續更新的藥物研發流程。

因此，本計畫將 GWAS、WES、scRNA-seq、RNA-seq 與 proteome 標準流程與工具鏈平台化，將多體學結果轉換為可直接被「決策層」使用的可計算證據資料包（例如：GWAS summary statistics、WES 功能註解變異表、Differential Expression Gene（DEG）共表達模組、細胞溝通網絡、PPI 模組與 Hub proteins 等）。為使多代理 AI（Evaluator / Designer / Clinical reasoning agents）能可靠協作並支援審計追溯，平台化機制將同步完成：(1) 臨床表型與樣本對應的結構化（Patient–sample mapping）、(2) 跨體學 Identifier（ID）對齊與語義一致化、(3) 證據來源/品質/批次資訊顯示保留、(4) 版本化輸出與可重現 Pipeline、(5) 可解釋的推論與決策紀錄（Reasoning logs）。

總體而言，各體學分析平台化的核心價值在於：將複雜、易漂移且高度依賴個人經驗的分析流程，轉換為可重現、可追溯、可版本化的證據產出 Pipeline，進而降低訓練與溝通成本、加速標靶–藥物決策迭代，並為多代理 AI 與臨床決策/虛擬介入模型提供可靠輸入基礎。

二、研究目標

為了達成上述研究目的，子計畫 1 設立七個研究目標，預計開發七個資料分析平台，架構圖及說明如下圖二所示：

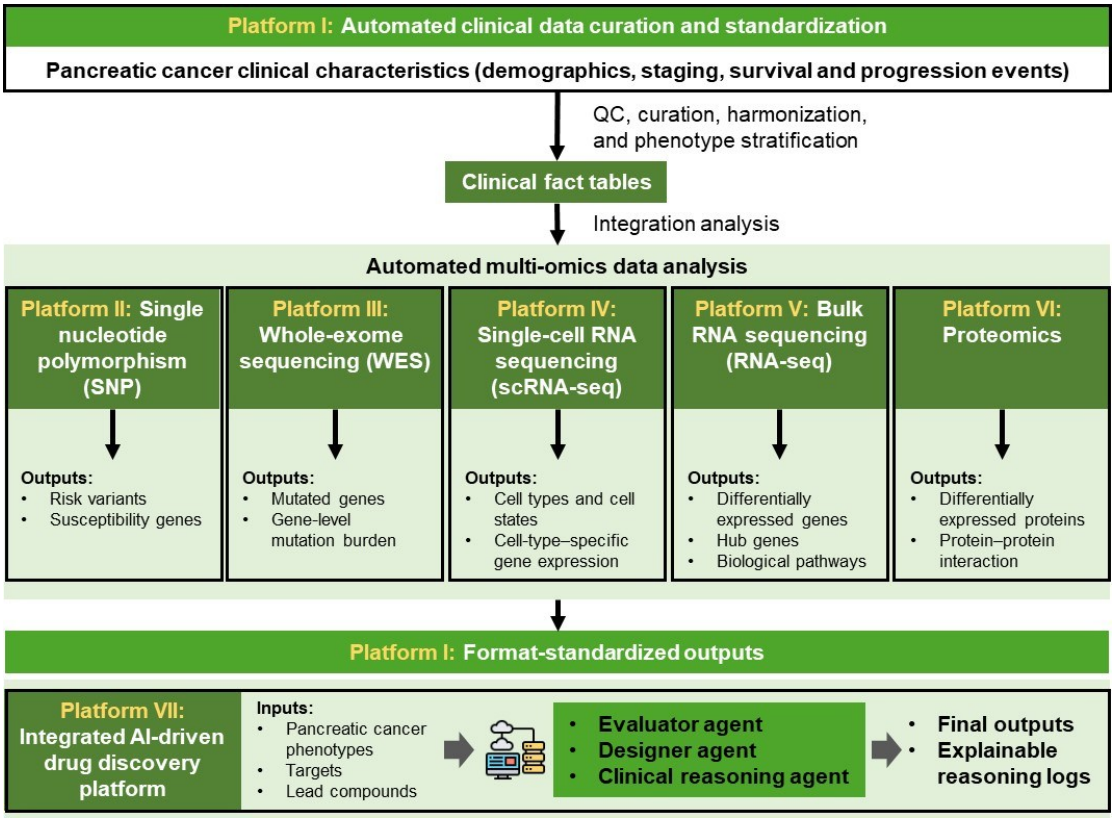

圖二、整合癌症多體學資料之標準化分析及證據化輸出建構平台架構圖

（一）研究目標一：共通資料標準化建構平台開發

本平台之研究目標在於建立一套跨平台共用臨床與多體學資料標準化與結構化流程，作為整體自動化分析架構中共通資料輸入與事實層（Facts Layer）基礎，以確保不同資料來源、不同分析平台與不同研究階段所產生資料，皆能在一致且可追蹤規格下整合與再利用。整體設計核心在於系統性整理臨床資料並統一資料格式、命名規則與欄位定義，同時對各類多體學分析結果與外部生物資料庫資訊標準化格式與整理結構，使其能直接銜接後續 GWAS、WES、scRNA-seq、Bulk RNA-seq 與蛋白質體等自動化分析平台。

在分析流程上，平台首先整合來自消化道癌症生醫資料庫與台灣上消化道癌症臨床試驗聯盟胰臟癌臨床資料，涵蓋人口學特徵、疾病診斷、分期、治療方式、治療反應與存活等資訊，透過自訂資料字典與欄位標準規範清理資料、缺失值處理與結構化整理，並進一步定義臨床表型與分層規則，以支援後續多體學分析之分組與比較。在多體學資料處理方面，平台針對 GWAS、WES、RNA-seq、scRNA-seq 與蛋白質體等原始資料或分析結果，統一其檔案格式與資料結構，並結合 R 與 Python 建立自動化之資料整合與一致性檢查流程，以確保不同平台間輸入與輸出可相互對齊。

此外，平台亦系統性整理外部公開生物資料庫之資訊，對齊跨資料庫之命名與識別碼轉換，確保基因、遺傳變異與蛋白等關鍵生物實體在不同資料來源間具有一致的識別基準。為強化資料可重現性與可追蹤性，平台同步設計結構化的 Metadata 描述與版本控管機制，完整記錄資料來源、處理流程與版本變更歷程。

最終，本平台將產出結構化且標準化之臨床資料表、臨床表型定義與分層規則文件、統一格式多體學資料與分析結果，以及標準化之外部資料庫資訊，並整合為可重現、可追蹤共通資料包，作為後續自動化平台二至六及相關決策與推論子計畫所共用之核心資料基礎。

（二）研究目標二：單核苷酸多態性（SNP）分析平台開發

本平台之研究目標在於建構一套整合式 GWAS 與 post-GWAS 分析流程，將原本仰賴程式語言操作之遺傳統計分析工具加以系統化與網頁化，提供使用者以直覺化介面分析參數設定、任務執行與結果管理，藉此降低分析門檻並提升整體分析流程可重現性與一致性。整體架構採用上下游分析概念，將 GWAS 視為上游核心分析步驟，其產生之 Summary statistics 可無縫銜接作為下游 post-GWAS 各類分析輸入，並支援不同 post-GWAS 方法之結果整合與比較，以利從多角度詮釋遺傳變異與疾病表型之關聯。

在分析流程上，系統首先於 GWAS 模組中，透過 PLINK 控制基因型資料品質，並依研究需求選擇以 PLINK 或 Scalable and Accurate Implementation of Generalized mixed model（SAIGE）執行全基因體關聯分析，以因應不同樣本數規模與表型分佈特性，最終產出標準化 GWAS summary statistics。後續 post-GWAS 分析則涵蓋多個功能模組，包括 Polygneic Risk Score（PRS）、Transcriptome-Wide Association Study（TWAS）、孟德爾隨機化（Mendelian randomization, MR）與 Fine-mapping。PRS 模組利用 PRSice 計算個人層級多基因遺傳風險評分，以評估累積遺傳效應與臨床表型之關聯；TWAS 模組則透過 Functional Summary-based Imputation（FUSION）結合多組織 Expression Quantitative Trait Loci（eQTL）基因表現預測模型，推估基因表現與疾病或性狀之關聯性，補足單純 SNP 層級分析在功能詮釋上的限制；MR 模組使用 Two sample Mendelian randomisation（TwoSampleMR），以遺傳變異作為工具變項，推論暴露變數對結果變數潛在因果效應，並同時支援單一暴露與多基因逐一分析之架構；Fine-mapping 模組則先以 Genome-wide Complex Trait Analysis - Conditional and Joint（GCTA-

COJO）分析條件以解析獨立訊號，再透過 FINEMAP 建立 Credible sets，並估計各 SNP 之 Posterior inclusion probability，以篩選具潛在因果角色之變異位點，最後結合 ANNOtate VARiation（ANNOVAR）註解 SNP 功能與標示目標基因。

透過上述整合式流程，本研究預期可系統性產出高品質 GWAS 與 post-GWAS 分析結果，包括遺傳關聯統計量、多基因風險評分、基因表現關聯、因果推論證據以及具功能意義之候選致病變異與基因，作為後續多體學整合分析與疾病生物機制推論之關鍵基礎。

（三）研究目標三：全外顯子定序（WES）分析平台開發

本平台之研究目標在於建立一套全外顯子定序（Whole-Exome Sequencing, WES）自動化遺傳變異分析與註解平台，系統性處理外顯子層級之變異偵測、功能註解與基因層級統計分析，並建構具高度可重現性之 Exome-wide Association Study（ExWAS）分析流程，以產出可直接銜接下游多體學整合分析與疾病標靶證據建構基因層級結果。

整體分析流程由原始定序資料或已對齊序列資料出發，結合參考基因組、樣本表型資料與共變數資訊，透過自動化流程完成變異呼叫、品質控制、功能註解與統計分析。在流程設計上，平台首先利用 Genome Analysis Toolkit（GATK）對齊序列後變異偵測與 Joint calling，產生高一致性之 SNP 與 Insertion-Deletion（InDel）變異資料，並搭配 GATK、Binary Call Format tools（BCFtools）與 PLINK 等工具控制變異品質與篩選，以確保分析資料在深度、品質分數、呼叫率與族群頻率等指標上符合分析標準。

隨後，透過 ANNOVAR 註解系統化之遺傳變異功能，整合功能區域、胺基酸變化、族群頻率以及多種 In silico 致病性預測指標，例如：Combined Annotation Dependent Depletion（CADD）、Polymorphism Phenotyping（PolyPhen）與 Sorting Intolerant From Tolerant（SIFT），以協助罕見變異之功能性分類與致病潛力評估。在統計分析層級，平台同時支援單一變異之 ExWAS 分析，以及以基因為單位之變異負荷分析，透過 PLINK、Efficient and Parallelizable Association Container Toolbox（EPACTS）與 Sequence Kernel Association Test（SKAT）等套件執行 Burden test、SKAT 與 Sequence Kernel Association Test – Optimal（SKAT-O）等方法，以評估罕見與低頻變異在基因層級上與疾病或表型之關聯性。

最終，平台將整合統計顯著性結果與功能註解證據，系統化彙整疾病相關之候選基因，並以標準化格式輸出高品質變異清單、完整註解之變異資料表、ExWAS 結果以及基因層級關聯分析成果，作為後續多體學證據整合、疾病生物機制解析與標靶優先排序之核心輸入資料。

（四）研究目標四：單細胞 RNA 定序（scRNA-seq）分析平台開發

本平台之研究目標在於建立一套單細胞 RNA 定序（single-cell RNA sequencing, scRNA-seq）資料之自動化分析與標準化流程，系統性解析細胞層級之基因表現特徵與細胞間交互關係，以建構可用於下游多體學整合與疾病情境建構之細胞層級生物證據。整體分析以單細胞表現矩陣為核心輸入，結合細胞與樣本註記資訊、基因註解資料、細胞類型參考標記基因，以及臨床表型或實驗條件分組資訊，透過模組化與自動化設計，完整涵蓋單細胞資料從前處理到高階生物詮釋之分析流程。

在分析流程上，平台首先利用 Seurat 套件控制單細胞資料之品質、正規化、批次效應校正與資料整合，並執行細胞分群，以建立穩定且可重現之細胞族群結構，隨後透過 Marker-based 方法註解細胞類型，可依需求採用人工策展或參考資料庫輔助之方式，以確保細胞類型定義之生物合理性。在細胞層級表現分析方面，平台將建構細胞類型特異性之基因表現特徵，系統性描繪不同細胞族群在不同疾病狀態或實驗條件下分子表現差異。進一步於網絡層

級，平台整合 High-dimensional Weighted Gene Co-expression Network Analysis（hdWGCNA）方法，依細胞類型或以 Pseudobulk 策略建構基因共表達網絡，辨識具生物意義之共表達模組與潛在關鍵調控基因。在動態分析層級，平台透過 Monocle、Slingshot、Cell–Cell Communication Analysis Tool（CellChat）推論細胞之發育或狀態轉換軌跡，以重建細胞狀態變化之連續性與方向性，解析疾病相關之細胞動態過程。此外，平台亦納入 CellChat 或 Cell–Cell Communication Database（CellPhoneDB）分析細胞–細胞通訊，系統性推論配體–受體互作關係與細胞間訊號傳遞網絡，補足單一細胞內分析在細胞互動層面的限制。

最終，平台將上述分析結果以標準化格式整合與輸出，包括單細胞與細胞類型層級之基因表現矩陣、細胞類型特異性表現特徵與標記基因、細胞基因共表達網絡與關鍵模組、細胞發育或狀態轉換軌跡，以及細胞–細胞通訊與配體–受體互作網絡，作為後續多體學證據整合、疾病生物機制推論與精準標靶探索之關鍵細胞層級資料基礎。

（五）研究目標五：RNA 定序（Bulk RNA-seq）分析平台開發

本平台之研究目標在於建立一套 RNA 定序（Bulk RNA-seq）資料之自動化分析與標準化流程，系統性解析基因表現層級之變化，以鑑定與疾病或表型相關之差異表達基因及其潛在生物功能，並進一步建構可用於下游多體學整合與標靶證據建構之基因層級表現證據。整體分析架構以 RNA sequencing（RNA-seq）原始定序資料為起點，結合參考基因組與基因註解檔、樣本分組與表型資訊，以及批次效應與臨床變項等共變數資料，透過模組化與自動化設計，完整涵蓋從資料前處理到高階功能詮釋之分析流程。

在分析流程上，平台首先檢查 RNA-seq 資料之品質與前處理，包含讀序品質控制、序列比對與基因層級定量，並可依分析需求選擇使用 Spliced Transcripts Alignment to a Reference（STAR）或 Hierarchical Indexing for Spliced Alignment of Transcripts 2（HISAT2 read alignment），搭配 featureCounts 或 Salmon 建構標準化之基因表現矩陣。隨後，透過適當之正規化方法校正樣本間技術性差異，建立可用於跨樣本比較之基因表現資料。在差異表達分析層級，平台整合 DESeq2、edgeR 與 Limma-voom 等主流程套件，比較不同表型或實驗條件下之基因表現差異，系統性鑑定差異表達基因，並同時考量共變數與批次效應對分析結果之影響。進一步於網絡層級，平台利用 Weighted Gene Co-expression Network Analysis（WGCNA）建構基因共表達網絡，辨識具高度共表達關係之基因模組，並解析其與疾病表型或臨床特徵之關聯性，以找出潛在關鍵調控模組與核心基因。

在功能詮釋方面，平台結合 clusterProfiler 與 Gene Set Enrichment Analysis（GSEA）等方法，分析生物途徑與功能富集，系統性評估差異表達基因與共表達模組所涉及之生物途徑與分子功能。最終，平台將各分析階段之結果以標準化格式整合與輸出，包括基因表現矩陣、差異表達基因清單、基因共表達網絡與模組結構、關鍵基因（Hub genes）以及生物途徑與功能富集分析結果，作為後續多體學證據整合、疾病生物機制推論與精準標靶探索之重要基因層級表現依據。

（六）研究目標六：蛋白質體（Proteomics）分析平台開發

本平台之研究目標在於建立一套蛋白質體（Proteomics）資料之自動化分析與標準化流程，系統性解析蛋白質表現層級之變化，以鑑定與疾病或表型相關之差異表達蛋白，並進一步建構蛋白質交互作用網路，解析關鍵功能模組與核心調控蛋白，作為下游多體學整合、疾病機制推論與標靶證據建構之蛋白層級基礎。整體分析流程以質譜定量之蛋白質體資料為核心輸入，涵蓋 Label-free 或標記式定量結果，並結合蛋白質鑑定與定量矩陣、樣本分組與表型資

訊，以及批次效應與臨床變項等共變數資料，透過模組化與自動化設計，完整銜接從原始定量結果到高階網路與功能分析之各個步驟。

在分析流程上，平台首先前處理蛋白質體資料與品質控制，透過 MaxQuant 或 Proteome Discoverer 完成蛋白質鑑定與定量，並正規化處理，以建構可用於跨樣本比較之蛋白質表現矩陣。隨後，在差異表達分析層級，平台整合 Limma 或 Mass Spectrometry Statistics（MSstats）等統計方法，比較不同疾病狀態或實驗條件下之蛋白質表現差異，系統性鑑定差異表達蛋白，並同時考量技術與臨床共變數對分析結果之影響。進一步於網路層級，平台結合 Search Tool for the Retrieval of Interacting Genes/Proteins（STRING）與 Biological General Repository for Interaction Datasets（BioGRID）等蛋白質交互作用資料庫，建構蛋白質–蛋白質交互作用（Protein–Protein Interaction, PPI）網路，並透過 Cytoscape 網路視覺化與模組分析，以辨識具生物意義之功能模組與潛在關鍵蛋白。

在功能詮釋方面，平台透過 clusterProfiler 與 Reactome Pathway Analysis（ReactomePA）分析生物途徑與功能富集，系統性評估差異表達蛋白與功能模組所涉及之生物途徑與分子功能。最終，平台將各分析階段之結果以標準化格式整合與輸出，包括蛋白質表現矩陣、差異表達蛋白清單、蛋白質交互作用網路、關鍵蛋白與功能模組，以及生物途徑與功能富集分析結果，作為後續多體學證據整合、疾病生物機制解析與精準標靶探索之重要蛋白層級證據來源。

（七）研究目標七：整合 AI 平台開發

本平台之研究目標在於將本計畫所建構之多體學自動化分析平台（平台一至六）與 AI 推論子計畫 2–4 整合為一套可實際運作之大型 AI 藥物開發平台，形成從資料、證據、推論到決策之端到端（End-to-End）系統架構。

此平台以「平台化」為核心設計理念，將原本分散於不同分析流程與子計畫中的功能，統一納入單一可擴充、可重複使用之系統中，使研究者能以一致的操作邏輯與資料介面，完成跨子計畫之整合分析與 AI 推論。平台建構完成後，使用者可直接輸入癌症（例如：胰臟癌）相關之臨床與疾病表型資訊，指定欲評估之標靶（例如：PAI-1/LRP1 等），並同時提供對應之藥物分子結構資訊（包含蛋白質/胜肽），平台即可自動串聯後端之多個 AI 代理人，展開完整之 AI 藥物開發推論流程。在系統運作上，平台將首先整合子計畫 2 所建立之標靶與藥物生物證據與信心決策架構，於明確疾病情境下評估標靶合理性、藥物–標靶關聯性與轉譯風險；接續銜接子計畫 3 之藥物分子結構優化代理人，針對輸入之蛋白質、胜肽結構設計空間探索與性質優化；最後，平台進一步整合子計畫 4 之虛擬臨床試驗與臨床可行性評估機制，模擬藥物於臨床情境下之反應趨勢、有效性與潛在風險。

整體平台架構亦支援多 Agent 協作之 AI 推論機制，使不同代理人間可資訊交換、結果回饋與決策協調，並同步保留完整且可追溯之 AI 推論與決策歷程，以利後續檢核、解釋與模型修正。最終，本平台將作為標靶與藥物優先排序、風險評估與決策輸出之整合中樞，並透過模組化與可擴充之系統設計，支援未來新疾病情境、新資料型態與新 AI 模型之快速導入，建立一套具長期發展潛力之 AI 藥物開發平台基礎。

三、分年研究內容與方法

（一）第一年：共通資料層建置與多體學平台雛型開發

第一年工作重點在於建立整體多體學分析架構所需之共通資料層，與各分析平台之初始雛型。首先，完成共通資料標準化建構平台（研究目標一），系統性整理胰臟癌臨床資料，

建立臨床表型定義、分層規則與 Patient–sample mapping，並完成跨體學資料之欄位定義、命名規範與結構化流程，作為後續所有分析平台之共通輸入與事實層（Fact Layer）。

在遺傳體學平台方面，本年度將完成單核苷酸多態性（SNP）分析平台（研究目標二）之核心功能建置，建立 GWAS 品質控制與全基因體關聯分析之自動化流程，並產出標準化之 GWAS summary statistics，作為後續功能註解與多體學整合之基礎輸入。

此外，自第一年下半年起，將同步啟動全外顯子定序（WES，研究目標三）、Bulk RNA-seq（研究目標五）與單細胞 RNA 定序（scRNA-seq，研究目標四）分析平台之雛型開發。此階段重點在於建立各平台之基本分析 Pipeline 與資料結構，包括變異呼叫與初步功能註解、基因表現定量流程、單細胞資料之前處理與細胞分群等，使各平台具備可運作且可銜接之初始能力，並完成與共通資料層之資料格式與識別碼對齊，為後續年度之深化與整合奠定基礎。

（二）第二年：多體學分析平台之功能擴充與協同開發

第二年工作重點在於既有分析平台之功能擴充與跨體學協同開發。在 WES 分析平台（研究目標三）方面，將強化變異功能註解、基因層級分析與 ExWAS 流程，並使其分析結果可穩定銜接至基因表現與細胞層級證據。

同時，Bulk RNA-seq（研究目標五）分析平台將完成差異表達分析、基因共表達網絡建構與生物途徑分析等核心模組，使平台可穩定產出具解釋力之基因表現層級證據。單細胞 RNA 定序分析平台（研究目標四）則將擴充細胞類型註解、細胞類型特異性表現特徵建構與基礎細胞互動分析功能，逐步形成可用於疾病情境解析之細胞層級分析能力。

本年度亦將同步推進 WES、Bulk RNA-seq 與 scRNA-seq 平台之資料結構與輸出格式整合，使遺傳、基因表現與細胞層級結果可一致化管理與交叉對照，強化整體平台之協同運作能力。

（三）第三年：蛋白質體平台建置與多體學分析平台定型

第三年工作重點在於完成既有多體學分析平台之定型，並導入蛋白質體分析平台。於第三年上半年，完成全外顯子定序（WES）分析平台（研究目標三）之最終建置與流程定型，使其成為穩定、可重現且可長期維運之分析平台，並正式納入整體多體學證據產出架構。

在轉錄體與單細胞體學方面，Bulk RNA-seq（研究目標五）與 scRNA-seq（研究目標四）平台將完成進階分析模組之建置，包括基因共表達網絡深化、細胞狀態轉換與細胞間通訊分析等，使平台具備完整之疾病情境解析能力。

同時，本年度將啟動蛋白質體（Proteomics）分析平台（研究目標六）之建置，完成蛋白質鑑定、定量與差異表達分析流程，建立蛋白層級證據之初始平台能力，並完成與前述體學平台之資料結構對齊。

（四）第四年：蛋白質體平台深化與整合式 AI 平台收斂

第四年之工作重點在於完成蛋白質體分析平台之深化，並將所有體學分析平台整合至整合式 AI 平台。蛋白質體分析平台（研究目標六）將完成蛋白質交互作用網路建構、功能模組辨識與關鍵蛋白萃取，並與遺傳體學與轉錄體分析結果檢核跨體學一致性，形成具高度轉譯潛力之候選標靶證據。

最終，本年度完成整合 AI 平台（研究目標七）之建置與整合，將前六項分析平台納入單一可擴充之系統架構中，讓使用者可於一致的操作介面下，直接利用多體學結構化證據評估標靶、藥物設計支援與臨床可行性推論，建立一套可長期維運且具決策價值之多體學 AI 平台基礎。

子計畫 2：疾病、標靶與藥物生物證據之推論與信心決策模組

一、研究目的

子計畫 2 的研究目的在於建立一套針對特定癌症的「標靶與藥物生物證據之可解釋信心評分模式」，透過本地部署 Llama-3_3-Nemotron-Super-49B-v1.5 作為主代理人（Main Orchestrator）調度分工專責的子代理人（Subagents）[52]，本計畫將實現以下重點目標：

（一） **自動化證據鏈檢索（Automated Evidence Chain Retrieval）：**本地部署 NVIDIA-Nemotron-3-Nano-30B-A3B，基於其強大的工具調用能力，實現「生物資訊子代理人（A1）」與「藥理學子代理人（A3）」，將基因體（SNP 基因型與 WES）、單細胞定序（scRNA-seq）、轉錄體（Bulk RNA-seq）與蛋白體（Proteomics）等多體學資訊，以及 DrugBank、PubMed 與 CheMBL 等藥理資訊的檢索流程模組化。系統將自動執行跨資料庫的證據檢索，確保證據資料的完整性與可回溯性。

（二） **建立可解釋的信心評分模型（Explainable Confidence Scoring）：**「評分子代理人（A2/A4）」將建立透明的評分權重計算公式。同時使用 Open Targets 評估，結合子計畫 1 建立的特定癌症臨床表型分層進行「情境化校準（Contextual Calibration）」。模型將明確量化證據強度，標註多體學證據衝突與不確定性的來源，提供具備邏輯支撐的決策依據。

（三） **台灣本地特定癌症臨床資料之微調與價值提升（Local Data Fine-tuning）：**利用台灣本地高品質的特定癌症（以胰臟癌為例）臨床資料建立黃金範例集，對各檢索子代理人監督式微調（Supervised Fine-Tuning）。這不僅能提升模型對特定臨床術語與台灣族群遺傳特徵的理解，更能確保輸出的證據格式符合標準化需求，實現精準醫療在地化與國際標準接軌的雙重目標。

綜上所述，本研究期望透過 AI 代理人技術，將過往依賴專家經驗的標靶篩選過程，轉化為可重現（Reproducible）、可稽核（Auditable）且具備臨床解釋力的自動化科學規格，加速特定癌症新藥標靶的發現與驗證。

二、研究目標

為有效解決上述研究問題，子計畫 2 提出整合多模態證據的 AI 藥物篩選與決策系統，如圖三所示。其核心由具備推理與規劃能力的「主代理人（Main Orchestrator）」進行全域控管。流程始於主代理人接收來自子計畫 1 的異質資料輸入，包含臨床表型、多體學數據（如 WES、RNA-seq）以及藥物資料庫資訊。主代理人依據任務需求，將分析工作分發至兩條平行的專家路徑：上層路徑由「生物資訊與統計分析」子代理人率先萃取疾病情境與標靶證據，並交由「標靶證據解讀與信心評分」專家進行生物權重計算；下層路徑則由「藥物標靶藥理學證據分析」子代理人彙整藥物特性，並傳遞給「藥物標靶藥理學證據量化評分」專家進行成藥性評估。這兩條路徑產出的結構化證據與信心分數最終回饋至主代理人進行綜合推論，量化出該「疾病-標靶-藥物」組合的治療潛力，並輸出包含可行性（Feasibility）、信心（Confidence）與優先序（Priority）的可解釋性決策報告，以支援後續的藥物開發策略 。

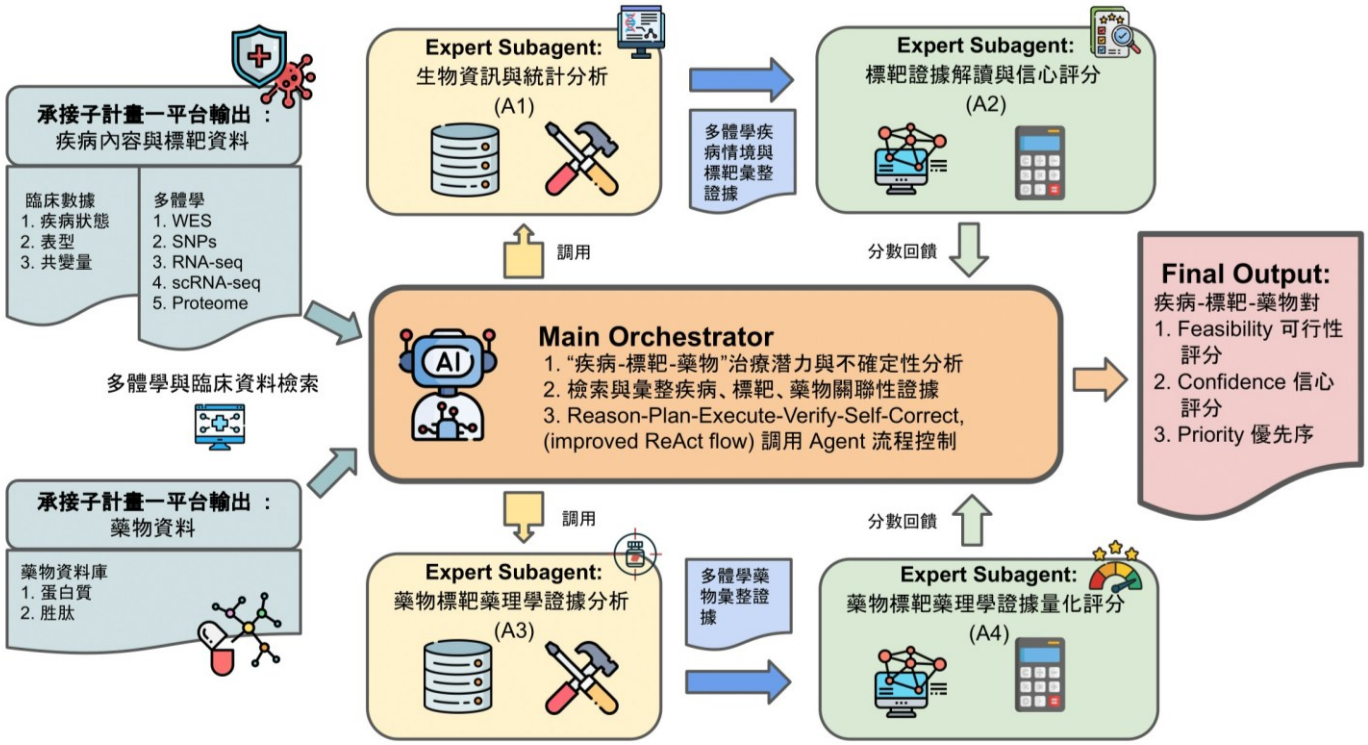

圖三、子計畫 2 系統架構圖

三、分年研究內容與方法

（一）第一年：建構生物資訊與標靶評分代理人體系：整合證據檢索 API 工具模組化與多體學信心指數決策實作

1. 「生物資訊與統計分析子代理人（A1）」證據檢索 API 工具模組化實作：

第一年的重點目標在於建立「多體學數據解釋與推論」的自動化 Agentic Workflow，並設計子代理人模型透過 Function Calling 機制使用可呼叫資料庫工具，以解決跨資料庫資訊耗時耗力之問題。本計畫實作參考 OmicsNavigator [16] 與 GeneRAG [17] 之研究結論，透過「檢索增強生成 (RAG)」結合大型語言模型作為資料庫檢索的 Controller，以提升多體學（Multi-omics）異質數據整合效率與推論準確度。

因此，本年度將聚焦於將子計畫 1 涵蓋之多體學資訊（SNP, WES）與癌症疾病情境資訊，搭配整合之 Pubmed 文獻庫及 Ensembl、GENCODE、Single Nucleotide Polymorphism Database（dbSNP）、ClinVar、The Genome Aggregation Database（gnomAD）、CADD、The Molecular Signatures Database（MSigDB）、Universal Protein Resource（UniProt）、STRING、Disease Gene Network（DisGeNET）、Online Mendelian Inheritance in Man（OMIM）等多體學資料集，透過標準化介面封裝技術，將其轉化為具備統一輸入輸出規範的 Callable Tools。此舉賦予代理人模型對異質生物資料的即時存取權限，完成從文獻蒐證到量化評分的最小可行代理人流程。

為實現高維度數據的「可重現性（Reproducibility）」與「跨標靶可比較性」，本計畫採用 Strict Schema Enforcement 策略，設計 JSON Schema 作為「結構化證據（Structured Evidence）」。所有經由 API 檢索之原始數據，皆須經由 Output Parser（輸出解析器）正規化並納入五大評估維度的考量：(1) 臨床表型關聯強度、(2) 跨體學一

致性、(3) 效應方向一致性、(4) 細胞類型或腫瘤微環境（TME）特異性、(5) 分析結果之統計支持度。

代理人將記錄每一筆檢索到的證據於 Agent Memory（代理人記憶狀態）中的元數據（Metadata），包括：原始來源 ID（Source provenance）、分析方法論（Methodology）、效應值（Effect Size / Direction）、以及資料版本（Versioning）。此設計旨在建立「可驗證的證據鏈」，產出具完整描述的「標靶生物證據概要（Target Biological Evidence Profile）」，作為下游信心評分的輸入。

2. 「標靶證據解讀與信心評分子代理人（A2）」基於「（A1）：基因體層級之表型關聯結果」資料彙整與評分流程設計與實作：

為確保從文獻證據到量化評分邏輯推演的嚴謹性，採用「多體學層級蒐證→轉換回標靶層級證據→考慮疾病情境證據→信心評分」之 Sequential Control Flow（序列化控制流）。

在實作上，A1 代理人首先執行 Parallel Retrieval Strategy（平行檢索策略），從 SNP、WES 等不同層級調用工具獲取數據；隨後，代理人接收各工具回傳之證據，呼叫彙整各證據的 Output Parser，彙整異質證據，紀錄以 Target - Disease Context 為核心的統一證據。執行「疾病情境注入（Disease Context Injection）」，利用 Tumor Microenvironment（TME）特異性數據過濾非病灶組織的雜訊，整套流程將基於完整的生物學上下文 Reasoning（推理）。

A2 子代理人之核心任務為擔任 Critic Agent 執行「信心評分（Confidence Scoring）」，其設計最高原則為「全證據溯源（Full Evidence Lineage）」。這意味著，最終產出的每一分 Target Biological Confidence Index（TBCI），在資料結構上皆保留指向原始資料源頭的關聯。評分邏輯採用加權貝氏模型（Weighted Bayesian Model）：

$$S_{SNP/WES_Score} = W_{evidence} \times S_{consistency} \times Context_{penalty}$$

其中，每一筆證據的分數 S 不僅取決於統計顯著性，更取決於其是否能「追溯回可信的證據資料源頭」。若某項證據缺乏明確的版本號或來源 ID，計算公式將透過自動將其權重 W 降低。最終輸出的決策報告，將不只是一個數字，而是一份可連結至原始文獻與資料庫紀錄的完整 Audit Log（審計日誌），確保真人專家能驗證 AI 的每一項判斷。

（二）第二年：基於 PubMed, DrugBank 建構藥理化學多代理人協作體系：整合證據檢索、推論評分與治療潛力之全局決策實作

1. 「藥理學與藥物化學證據檢索子代理人（A3）」PubMed、DrugBank 檢索 API 工具模組化、調用流程實作：

繼生醫目標（2A）完成多體學與臨床數據之標靶層級生物證據建構後，第二年度首要任務為由「藥理學與藥物化學證據檢索子代理人（A3）」針對「藥理學與藥物化學」，系統性、自動化建構與特定癌症（以胰臟癌為例）情境連結之證據檢索、彙整。研究內容將以 **DrugBank** 與 **PubMed** 兩主流藥物資料庫為主要來源。PubMed 為非結構性文獻資料，首先將引入的 **Vision-Language Model（VLM）** 搭配 Optical Character Recognition（**OCR**）技術，搜尋與存取文字與證據。在實作流程上，（A3）代理人將執行兩種檢索策略：一方面透過標準化 API 工具直接從資料庫提取結構化欄位；另一方面則視覺化解讀 PubMed 文獻，利用 VLM 的圖表理解能力（Chart Understanding）自動摘要論文中的劑量反應曲線圖或結合實驗表格，檢索出計算所需數值。

為確保資料擷取能滿足後續計算需求，本計畫定義嚴格的 **Data Schema（資料模式）**，強制將藥物屬性（如抗體）、作用型態（抑制或活化）、定量活性指標（如 IC50、

EC50、Kd）、選擇性以及實驗模型之情境相關性（例如：是否為 PANC-1 細胞株或類器官）等異質資訊，全數通過 **Output Parser** 正規化處理成 **JSON 資料型態**，並保留每一筆數據之 Digital Object Identifier（DOI）或 PubMed Unique Identifier（PMID）引用來源與版本資訊，建立可回溯的藥理學證據基礎。

2. 「藥物–標靶證據解讀與推論專家子代理人（A4）」基於「（A3）：藥物資料庫檢索與彙整」資料彙整與評分流程設計與實作：

承接（A3）產出之結構化證據，**「藥物–標靶證據解讀與推論專家子代理人（A4）」**為一具備 **Function Calling** 能力的計算推理引擎（Computational Reasoning Engine），其運作邏輯並非單純的語言生成，而是動態調用外部計算工具運算，以確保精確評分。

（A4）在接收到標準化（A3）彙整證據後，將依據證據類型觸發特定的計算函數，例如呼叫 calculate_binding_affinity_score 針對多重來源的 Half Maximal Inhibitory Concentration（IC50）運算幾何平均並正規化，或呼叫 compute_context_relevance 計算實驗模型與癌症情境的語意相似度。子代理人將執行加權運算邏輯，將 DrugBank 的研發狀態與 PubMed 的實驗數據強度轉化為數值。最終，（A4）將綜合產出一份包含「藥理學、藥物化學分數」與「情境信心指數」的決策，為上層決策提供具備量化依據的輸入。

3. 「主代理人」調用「子代理人」分析藥物-標靶-疾病治療潛力與不確定性流程設計與實作：

在全系統的決策層級，本計畫引用 **ToolOrchestra [18]** 多代理人協作框架，建構具備全域視野的 **Main Orchestrator**。主代理人不僅作為任務路由器，更負責動態生成 **Task Dependency Graph**，當接收到評估請求時，會並行呼叫生物資訊代理人（A1/A2）與藥理代理人（A3/A4）獨立的證據檢索與評分。待各子代理人回傳結果後，主代理人將執行 **Chain-of-Thought（CoT）**跨域推理，交叉比對生物學潛力與化學成藥性的權衡關係。團隊將針對「生物信心極高，但藥化性質不佳」之衝突情境，於 analyze_tradeoff_risk 函式中實作基於失效模式與效應分析（**Failure Mode and Effects Analysis, FMEA**）的決策，以提供條件式推理策略。函式暫定義三大檢核邏輯：

(1) **ADMET 受限：**檢測分子修飾位點，評估**前驅藥物（Prodrug）**設計可行性。

(2) **結合位點不佳：**計算表面可及性與泛素化潛力，判斷轉向 **Proteolysis targeting chimeras（PROTACs）蛋白降解療法**之機會。

(3) **安全性風險：**掃描已核准藥物之結構相似性，評估**藥物重新定位（Drug Repurposing）**。 此設計確保代理人能輸出一份帶有「有條件通過」標記的優化建議報告，而非因單一藥化缺陷直接淘汰高價值標靶。

舉例來說，若遭遇「生物信心極高，但藥化性質不佳」的衝突情境，主代理人將主動調用 analyze_tradeoff_risk 工具分析風險，識別該標靶是否具備前驅藥物設計或藥物重新定位的潛力，而非直接淘汰。主代理人輸出整合性決策報告，明確標註治療潛力等級，並條列來自不同層級的「不確定性來源」，實現具備邏輯解釋力的精準藥物開發決策支援。Main Orchestrator 產出「疾病-標靶-藥物」組合的可解釋性決策報告將會傳送給子計畫三。

（三）第三年：建構臨床表型導向之多體學轉譯與藥理化學證據建模代理人體系：流程設計與 ChEMBL 工具模組化實作

1. **「生物資訊與統計分析子代理人（A1）」基於「單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」調用模組流程設計：**

本子代理人(A1)之核心任務在於建立「臨床表型導向(Clinical Phenotype-Driven)」的自動化證據整合架構，旨在透過程式化邏輯將異質的生物數據轉譯為可量化的信心指數輸入。（A1）將「單細胞定序所鑑別之細胞類型特異性表現與細胞狀態訊號」以及「轉錄體與蛋白體之差異表現與共表達模組特徵」，在系統提示詞 **Chain-of-Thought（CoT）**Prompting 統一彙整具備生物學語意的標準化「基因/蛋白質實體」。此設計確保不同技術平台（scRNA-seq, Bulk RNA-seq, Proteomics）的證據能在同一座標系下**交叉驗證**。檢核與臨床表型之關聯強度、跨體學一致性、效應方向一致性、細胞類型或腫瘤微環境特異性，以及分析結果之可重現性。

最終，所有彙整與 Function Call 調用到之資料庫、文獻證據將被存入 **Structured Evidence Container（結構化證據容器）**，記錄證據來源、分析方法論、效應方向與大小、統計支持度、細胞/組織特異性與資料版本資訊，以確保全鏈路的可追溯性與跨標靶可比較性，並輔以國際開源資源檢核外部一致性，產出具完整證據描述之標靶生物證據概要，作為下游信心評分分析之基礎輸入。

針對 scRNA-seq 單細胞數據，（A1）實作 **Cellular Context Decoding（細胞情境解碼）**的 **ReAct(Reason+Act)**迭代推理流程。代理人首先執行 **Context-Specific Filtering（情境特異性過濾）**，利用 **CoT** 推理路徑鎖定病理細胞群，例如：Cancer-Associated Fibroblasts（CAF）、Exhausted T Cells 中的特異性標靶；接著透過 **Function Calling** 動態調用狀態分析工具，執行 **State-Function Mapping（狀態功能映射）**邏輯，將標記基因集（Gene Signatures）自動轉譯為惡性功能狀態，例如：Epithelial-Mesenchymal Transition（EMT）或缺氧；最終引入 **Cross-Omics Genetic Anchoring（跨體學遺傳錨定）**機制，回溯驗證該單細胞特徵是否具備 GWAS/WES 遺傳變異支撐。

在轉錄體（Transcriptomics）與蛋白體（Proteomics）層面，代理人分別建立「系統生物學模組化」與「功能執行力」之驗證邏輯。針對轉錄體，（A1）採用 **Dynamic Phenotype Screening（動態表型篩選）**準則，透過工具調用僅保留與預後具顯著相關之差異表現基因，並利用 WGCNA 概念識別共表達模組中的 **Hub genes（關鍵基因）**，輔以 cis-expression Quantitative Trait Locus（cis-eQTL）驗證強化遺傳調控證據。針對蛋白體，系統設計 **Translation Consistency Check(轉譯一致性檢核)**的雙向驗證規則，剔除 mRNA 與蛋白表現不一致的偽陽性，並依據次細胞定位資訊自動執行 **Druggability Triage(成藥性分流)**，判別適合抗體開發策略；同時建立 **Structural Risk Alert（結構風險預警）**機制，評估非同義突變是否破壞關鍵功能域，藉此排除構形不穩定的無效標靶。

2. **「藥理學與藥物化學證據建模子代理人（A3）」CheMBL 檢索 API 工具模組化、調用流程實作**

本階段目標建構 **ChEMBL High-Level Tool Layer（高階工具層）**，利用 **Function Calling** 技術將複雜的資料庫查詢封裝為標準化的 **API Functions**，以支援從證據檢索到信心指數換算的自動化流程。核心工具包括 retrieve_target_bioactivity（將 IC50、Inhibitory Constant（Ki）等活性數據標準化為 nM 單位）、assess_compound_selectivity（計算選擇性係數以量化脫靶風險）及 extract_mechanism_of_action（將文字描述轉譯

為標準化調控模式）。最終輸出被定義為符合嚴格 **JSON Schema** 的標準化物件，以提供下游模型精確的定量藥理特徵。

為實現從「定性機制」到「定量活性」的跨越，（A3）子代理人採用 **Sequential Tool Invocation Architecture** 蒐集證據。代理人首先觸發 DrugBank 驗證模組確立基礎機制，隨後啟動 ChEMBL 核心模組，透過 retrieve_target_bioactivity 獲取高精度的定量參數，並接續調用 assess_compound_selectivity 運算選擇性係數。最後，系統自動觸發 PubMed 模組補足 ADMET 與毒性數據。此 **Orchestrated Workflow** 確保所有異質數據皆經過 **Normalization Pipeline（正規化管線）**彙整為單一標準化 JSON 證據物件，保證最終決策係基於「實驗級」的精準藥理特徵。

（四）第四年：建構臨床表型導向之多體學標靶驗證與評分代理人體系：整合證據實體化、可解釋性信心評分與在地化微調實作

承接第三年度完成之「代理人邏輯架構設計」與「資料介面定義（Schema Definition）」，本年度（第四年）之要點任務在於將上述設計轉化為可執行之**全系統自動化 Pipeline**。重點在於將（A1）子代理人之推理設計，實作成具備完整檢索能力與動態決策機制的代理人自動化程式碼，確保其能自動搜尋多體學資料空間，並產出符合預定義規格、可回溯之結構化證據，最終透過在地化臨床數據的監督式微調（SFT），完成系統的落地驗證與優化。

1. 「生物資訊與統計分析子代理人（A1）」基於「單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」調用模組流程設計與實作：

本年度（A1）代理人將依據第三年確立之推理架構，正式執行「多體學證據實體化」。其運作架構由三個專責的工具調用模組組成，旨在將異質數據自動轉化為可被（A2）讀取的結構化證據：

(1) 單細胞情境解碼之實作：針對 scRNA-seq 單細胞數據，（A1）實作一套基於 **ReAct（Reason+Act）**框架證據彙整流程。代理人首先接收來自子計畫 1 的疾病情境、標靶資訊作為 Context，透過 **Function Calling** 呼叫過濾函數，依據預設的統計閾值（log2FC > 1.0, p_val_adj < 0.05）鎖定如 CAF 等特定病理細胞群的高顯著標記基因。隨後，代理人自動調用 Gene Set Enrichment Analysis in Python（GSEApy）或 MSigDB API 執行路徑分析，若推理引擎識別出 EMT 或缺氧等關鍵惡性特徵（False Discovery Rate, FDR < 0.05），將對其標註，並定義為「惡性驅動狀態」並排序關鍵基因。最終，代理人執行 **Genomic Anchoring（遺傳錨定）**程序，串接 Ensembl 與 dbSNP API 檢索啟動子區域變異，並交叉比對 GWAS 統計數據，針對具風險位點支持的標靶寫入 Genomic_Anchor: True 屬性，完成從單細胞表型到遺傳驅動證據的實體驗證。

(2) 轉錄體 API 編排之實作：在轉錄體（Transcriptomics）處理層面，（A1）將邏輯轉化為自動化的 **API Function Call** 流程。針對差異表現基因（DEGs），程式並行調用 DisGeNET 與 OMIM API 比對資料，依據是否包含"Pancreatic Neoplasms"等關鍵字，自動將標靶分類為 Known_Association 或 Novel_Target。接著，代理人利用網路拓撲分析工具計算 WGCNA 模組基因之連接度（Eigengene-based Connectivity, kME > 0.8），篩選出關鍵基因 （Hub genes），並透過 STRING API 執行 **Multi-hop Verification（多跳驗證）**以確認其 PPI 網絡中心性。最後，整合 GTEx API 查詢胰臟組織的 eQTL 數據，若確認為顯著 Expression Gene（eGene），則註記 Tissue_Specific_Regulation: Verified，完成組織特異性調控的實證。

(3) **蛋白體多模態融合之實作：**針對蛋白體（Proteomics）數據，（A1）執行 **Multi-modal Data Fusion（多模態數據融合）**邏輯。代理人首先合併轉錄與蛋白數據，利用 Pearson 相關係數（>0.5）與 Protein_Log2FC（>1）作為過濾器，篩選高轉譯效率標靶。接著，調用 UniProt API 解析 Subcellular localization 與 Feature 欄位，利用規則比對模組自動判別藥物開發策略，將其標記為"Antibody/ADC"（膜蛋白）或"Small Molecule"（胞內蛋白）。最後，整合 ClinVar 與 CADD API **Structural Risk Assessment（評估結構風險）**，針對 CADD Score > 20 且位於關鍵 Domain 之突變發出 Structural_Risk_Warning，完成結構功能的量化評估。

2. 「標靶證據解讀與信心評分子代理人（A2）」：基於「（A1）：單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」資料彙整與評分流程設計與實作：

（A2）代理人旨在建立可解釋的標靶驗證體系，將（A1）彙整之異質多體學證據轉化為具備臨床權重之量化指標。（A2）的核心演算法採用 **Bayesian Updating（貝氏更新）**邏輯進行信心推論。

首先，代理人透過 Open Targets Graph Query Language（GraphQL）API 取得全球標靶—疾病關聯分數，將其設定為 **Prior Probability（先驗機率, S_{Base}）**。隨後，結合生醫目標 1 之臺灣特定癌症臨床表型分層，與（A1）輸出之 scRNA-seq、轉錄體及蛋白體證據作為 **Likelihood**，執行「情境化校準（Contextual Calibration）」演算法以計算 **Posterior Probability**。系統將自動計算加權總分，針對具備跨體學一致性、本地統計顯著性及特定微環境細胞狀態者給予正向加權；反之，若證據僅來自單一層級、缺乏蛋白驗證或與國際資料庫方向性衝突，代理人將自動觸發 **Uncertainty Penalty（不確定性懲罰）**機制並生成風險旗標。

最終，（A2）將產出包含「最終信心評分」、「證據來源細項」與「風險旗標」的標準化 **JSON Decision Object（決策物件）**，供後續（A3）藥物媒合代理人優先排序與過濾候選標靶。最後，主代理人將整合來自 A1 與 A2 的完整多體學證據（涵蓋 SNP, WES 等格式化資料）及其信心評分，以及 A3 與 A4 的藥理學與藥物化學證據資料。最終產出具備可解釋性的「疾病-標靶-藥物」組合決策報告，並轉化為標準化表格傳送予子計畫三。此報告將詳列候選標靶的多面向證據、既有藥物資訊與藥效相關資料，作為子計畫三進行後續藥物設計與驗證的關鍵先導資訊。

3. 使用本地臨床資料微調子代理人提升系統表現：

為提升各專家子代理人在特定臨床情境下的準確度，本計畫將利用高品質本地特定癌症臨床資料，建立 **Instruction Tuning Dataset（指令微調資料集）**，也就是所謂的「黃金範例資料集」。本計畫將真實的臨床提問、正確的資料庫 API 檢索指令（包含精確的參數設定）以及標準化的 JSON 輸出結果配對成訓練樣本，針對各子代理人執行 **Supervised Fine-Tuning（SFT, 監督式微調）**。

此訓練過程旨在讓模型學習兩大重要能力：首先是 **Semantic-to-API Logic（語意轉代碼邏輯）**，使其在面對「具有 Kras 突變的 PDAC 患者」等特定術語時，能生成精確的外部資料庫查詢語法；其次是 **Schema Adherence（格式遵從性）**，確保輸出的證據物件嚴格遵從預定義的 JSON Schema，以便下游子計畫解析。透過此在地化數據的微調，不僅能強化模型對特定癌症領域知識的理解，更能透過 **Grounding（基底錨定）**機制顯著降低幻覺（Hallucination），提升系統在處理複雜臨床情境時的穩定性與輸出正確率。

子計畫 3： AI 藥物設計與最佳化 - 以 PAI-1 之胜肽先導分子為主案例

一、研究目的

癌症整體預後不佳且常在晚期才被診斷，臨床上可選擇的治療方案有限，使得「找得到、設計得出、評估得快」的新藥開發策略具有明顯迫切性。本整合型計畫以「人類專家藥物分析流程自動化與最佳化平台」為主軸，將藥理、藥物化學、分子生物、臨床推論與計算方法串接為一套可重複執行的研究流程，以縮短從標靶確認到候選藥物最佳化的決策時間，並提升整體分析的可驗證性與可重現性。

在整體計畫架構中，子計畫 2（Evaluator Agent）聚焦於候選標靶與既有藥物/先導分子的系統性彙整與評分，並以標準化表格輸出候選標靶的多面向證據、既有藥物資訊與藥效相關資料，作為後續設計的先導資訊；子計畫 4（Clinical Reasoning Agent）則以 PBPK 與 QSP 等方法，將候選分子轉譯到「可能的臨床暴露量與藥效路徑動態」推論與風險提示。子計畫 3（Designer Agent）位於兩者之間，必須把子計畫 2 的先導資訊轉換成一批可被子計畫 4 進一步模擬的候選分子版本，並能根據子計畫 4 的回饋再做設計修正。

然而，現有 AI 藥物設計流程常見的瓶頸在於：(1) 資料型態分散（蛋白質/胜肽的 Fast-All（FASTA）序列、蛋白質三維結構 Protein Data Bank（PDB）檔、以及文獻/資料庫證據表格），跨工具串接成本高；(2) 藥物設計需要同時考量親和力（例如以 ΔG、K_d、IC50 等指標表徵）、選擇性、以及 ADMET 等多參數條件，屬於典型的多目標最佳化；(3) 當設計流程需要大量候選變體、或需要整合長篇證據與結構描述時，模型推論與計算效率會直接影響「是否能比人快」以及能源成本。子計畫 3 除建立可落實的 Designer Agent，也將在必要處導入高效率注意力（Attention）計算方法，讓平台在長序列與大量候選情境下仍可維持高吞吐量，並對應節能減碳的研究趨勢。

二、研究目標

子計畫 3（Designer Agent）之研究目標，在於建構一套可重複執行、可驗證且具臨床導向之 AI 藥物設計與最佳化平台，負責將子計畫 2 所彙整之候選標靶與先導分子證據，轉化為一批可供子計畫 4 進行 PBPK/QSP 臨床推論與虛擬試驗評估之候選分子版本，並能依據臨床層級回饋進行反覆設計修正。以胰臟癌 PAI-1 為示範標靶，子計畫 3 欲回應之核心問題在於：於既定疾病情境與作用機轉（Mechanism of Action, MOA）限制下，如何從既有先導分子出發，系統性產生並篩選出在標靶作用強度、選擇性與 ADMET 等多參數條件間取得平衡、且更適合進入臨床推論階段的候選分子，使藥物最佳化流程不再僅依賴單次篩選或人工經驗判斷，而能透過平台化與自動化流程加速收斂。為對齊整合型計畫之整體設計，子計畫 3 同時處理至少兩條先導路徑：一為以本團隊既有先導胜肽（Peptide-001）為核心之胜肽設計案例，另一為由子計畫 2 彙整之既有藥物或文獻先導分子作為對照，並以一致資料格式與設計流程進行最佳化，以確保不同分子型態之設計結果具可比較性與可整合性。研究範疇上，子計畫 3 支援胜肽/蛋白質分子型態，分別以 FASTA/ PDB 與 Simplified Molecular Input Line Entry System（SMILES）/ Structure-Data File（SDF）作為核心表示，使所產生之候選分子能直接銜接後續之臨床推論與實驗驗證需求。Designer Agent 的主要輸入來自子計畫 2 所建立之標準化資料結構，涵蓋標靶多面向證據、既有藥物資訊與先導分子起點；在此基礎上，系統將產生候選變體庫，並針對每一候選分子提供結構描述、預測之結合相關指標（如 ΔG、K_d 或 IC50）、ADMET 與安全性風險評估，以及具可追溯性的設計依據，其輸出將封裝為結構化之「候選分子套件」，可直接供子計畫 4 進行參數化建模與臨床推論使用，並同步產出可驗證之設計決策報告，以支援後續臨床回饋與實驗資源配置。子計畫 3 之整體系統架構與四年期建置流程，已彙整如圖四所示，以呈現 Designer Agent 在整合型計畫中由基準建置、最佳化到臨床回饋之角色定位。

為使上述設計與最佳化目標得以具體落實於可執行之系統流程，子計畫 3 之 Designer Agent 採取循序漸進之四年期平台建構策略。於第一年，系統將聚焦於基準設計 Pipeline 與資料基礎之建置，完成資料與結構表示之標準化、基礎結構建模，以及初步之評分與篩選機制，產出具一致格式與可追溯來源之初始候選分子，作為後續最佳化之共同起點。第二年則在此基礎上，導入具可解釋性之混合式最佳化流程，包含更精細之結構評分、深度突變掃描與設計可解釋性分析，並針對長序列與大量候選分子所帶來之計算瓶頸，整合高效率注意力加速方法（如 PSOS），以在維持高精度與可解釋性的前提下，顯著提升候選生成與篩選效率。第三年進一步將設計流程由單純結構與分子層級最佳化，擴展至多參數整合與臨床導向回饋，透過風險評估模組與臨床推論回饋介面，形成「設計—評分—臨床回饋—再設計」之閉環迭代流程，使候選分子能在親和力、選擇性與可開發性等條件間取得更符合臨床需求之平衡。最終於第四年，完成端到端之示範案例與平台化部署，將整體 Designer Agent 整合為可長期維運、可擴充之設計系統，並透過實際案例驗證其在前臨床決策支援與平台化應用上的實用價值。

整體而言，子計畫 3 最終研究目標並非僅產出單一候選分子，而是建立一套能在「設計—評分—去風險—臨床回饋」之間反覆迭代的 AI 藥物設計核心能力，使藥物最佳化流程得以與臨床推論系統緊密耦合，作為整合型計畫中承上啟下、連結證據整合與臨床決策之關鍵設計引擎。

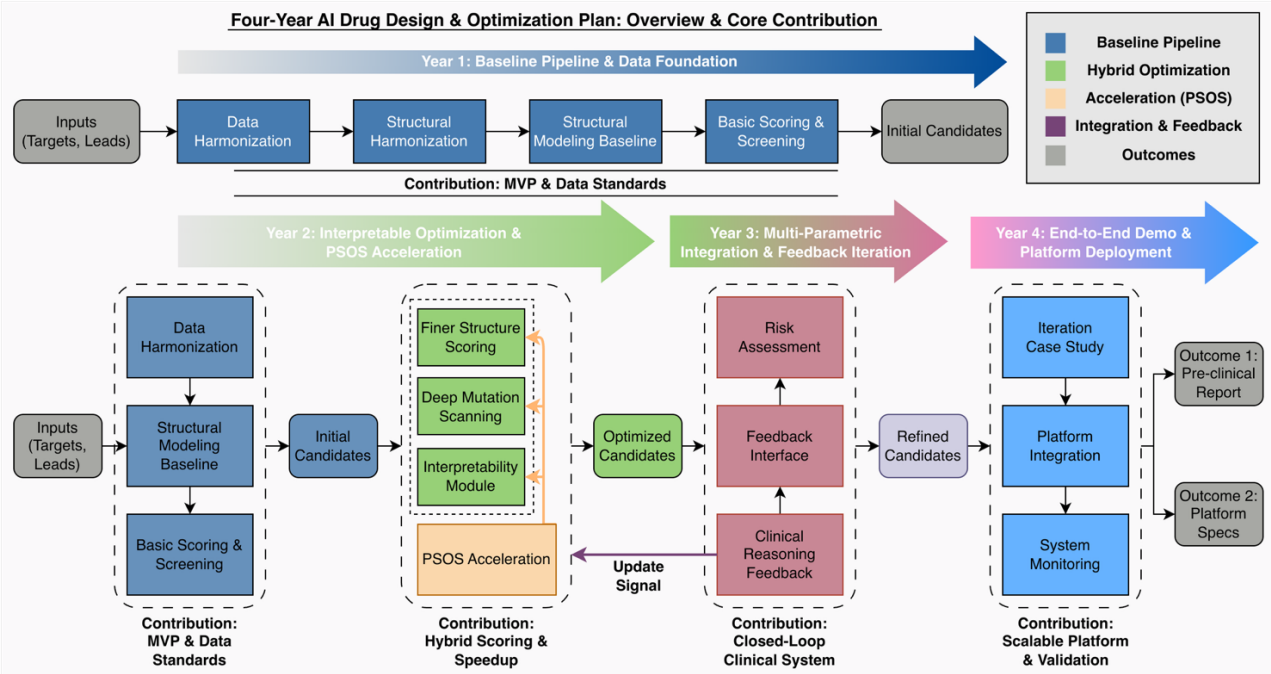

圖四、子計畫 3 內部三階段流程與 PSOS 加速模組位置示意圖

三、分年研究內容與方法

（一） 第一年：建立可執行 Baseline 與資料/結構 Pipeline，完成初步候選生成與評分

第一年的重要性在於建立「可以真的跑起來」的 Baseline。對於一個以藥物最佳化為核心的 Designer Agent，若沒有可重複執行的資料流、結構建模與評分流程，後續任何精度提升或效率加速都缺乏比較基準。因此本年度的目標是把子計畫 2 的輸入正式接上生醫目標 3，並完成一條可產生候選變體、可產生結構與評分、且能封裝送入子計畫 4 的最小可行流程（Minimum viable pipeline）。

在資料面，子計畫 3 將依照生醫目標（2A）–（2D）的表格格式建立匯入與一致化規則，將候選標靶（例如：PAI-1）、疾病情境、既有藥物與先導分子資訊，轉換成 Designer Agent 可直接使用的條件 c。此處特別強調「欄位固定」與「證據可驗證」：每一筆分數都必須能回

指到來源資料庫（例如：Open Targets、DrugBank、ChEMBL 等），以避免在設計端出現無法追查的黑盒子結論。另一方面，對於分子表示，本年度會支援胜肽/蛋白質路徑：胜肽以 FASTA 序列為主，必要時搭配 PDB。化學結構處理將以 Rational Discovery Toolkit（RDKit）[33]標準化、去鹽與衍生描述子計算，作為後續評分與相似度搜尋的基礎。

為使子計畫 3 與生醫目標 3 流程圖一致，本子計畫將把生醫目標（2A）–（2D）視為「標準化生醫資料」的核心，並在匯入後補齊四類設計端必要輸入：其一為序列與結構（Sequences & Structures），以 FASTA/PDB 與 AlphaFold [23]、ESMFold 等結構產生結果統一表示；其二為可修飾位置清單（Modifiable Sites List），由本年度之互作指紋與突變掃描自動產生，並固定欄位化；其三為動力學資料（Kinetic Data），保留 K_d、 k_on / k_off、Surface Plasmon Resonance（SPR）曲線等資訊與量測條件；其四為生物物理限制（Biophysical Constraints），以量測條件、開發性門檻與子計畫 2/4 提供之限制條件（例如可接受之免疫風險、聚集風險上限與目標暴露窗）形成一致化 Constraint 欄位。

在結構面，本年度將建立「標靶結構→候選結構→結合評分」的基準流程。對標靶 PAI-1 的三維結構，子計畫 3 將以 AlphaFold [23] 與 ESMFold [24] 等方法建立結構假設，並視需要以 CHARMM [26] / CGenFF [27] 最小化能量，以降低不合理幾何造成的評分偏差。對候選分子而言，胜肽/蛋白質候選可由先導序列出發改造點突變或片段並生成結構；對胜肽則先以可行的 Docking/能量評分流程建立排序，再逐年導入更精細的 AI-Physics hybrid 最佳化。

在「可修飾位置清單」的建立上，本年度將以受體–配體複合體的局部互作為核心剖析關鍵殘基：先以幾何條件辨識氫鍵、鹽橋、疏水互作等互作種類，並以 PLIF（Protein–Ligand Interaction Fingerprint）形式將互作指紋標準化，使不同候選之間可直接比較。對於胜肽/蛋白質候選，將進一步以 Alanine scanning 或等效的 In silico 突變掃描，估計單點突變對結合分數與互作網路的敏感度，從而把「可調整」與「不宜調整」的位置分開。可修飾位置清單將作為後續動態最佳化掃描的搜尋空間，並在送入子計畫 4 或規劃實驗時保留其證據來源與推導脈絡。為對齊生醫目標 3 流程圖所列之 Modifiable Sites List，子計畫 3 將此清單以固定資料格式輸出（例如：residue_index、allowed_mutations（允許替換之胺基酸集合）、interface_importance_score、interaction_type 與 evidence_source），並作為第二年動態最佳化掃描（Dynamic Optimization Scan）之主要輸入約束，確保「AI 變更」集中在可能影響結合機制的關鍵位置。

此外，本年度將把動力學資訊納入資料結構，而非僅使用平衡狀態的結合分數。對於可取得 k_on / k_off、K_d 或 SPR 曲線的先導分子，本計畫將在資料匯入時保留其測量條件、樣本濃度與誤差範圍，並把這些資訊轉換成設計端可用的限制條件（例如期望的解離速率上限、或結合半衰期下限）。此作法可使後續最佳化不僅追求「黏得緊」，也能兼顧「黏得久/解離得慢」等更貼近療效的性質。

而在藥物性質與安全性方面，本年度將把 ADMET 早期篩選納入 Baseline，子計畫 3 將以 ADMETlab 2.0 [29]建立吸收、分布、代謝、排除與毒性等多任務預測，並以 Tox21 任務 [32]做為毒性分類的基準補強。對胜肽/蛋白質候選，將以 NetMHCpan [30]評估免疫原性相關風險 (例如可能的表位呈現) ，並加入聚集風險的基本指標，以避免候選在設計階段就朝不利於開發的方向漂移。對於合成可行性，子計畫 3 將以 AiZynthFinder [28] 規劃逆合成路徑，形成「結構看起來可行」之外的第二道工程門檻。

當資料齊備後，本子計畫將「從先導分子產生更佳版本」視為多目標最佳化問題。令候選分子以 $\boldsymbol{x}$ 表示（對胜肽而言，x 可為胺基酸序列），Designer Agent 的任務是從搜尋空間中

找到一組候選集合 **X***，使其在標靶作用與可開發性指標上同時達到目標門檻。對結合強度而言，常以結合自由能 ΔG 連結到解離常數 K_d(值越小通常代表結合越緊) ，其關係可寫為：

$$\Delta G = RTln(K_d)$$

亦可使用對數尺度以便比較（例如 pK_d 越大，代表K_d 越小）：

$$pK_d = -log_{10}(K_d)$$

在實務上，子計畫 3 會把結合相關指標（例如：Docking score、ΔG/K_d或 IC50 的預測）、ADMET 風險、以及合成可行性等轉換成同一尺度的分數，形成候選排名。令 f_bind(x)、f_admet(x)、f_synth(x)分別代表結合、ADMET、合成可行性之標準化分數（分數越高，代表越理想），則可用加權目標函數描述單一候選的綜合評分：

$$J(\boldsymbol{x}) = w_1 f_{bind}(\boldsymbol{x}) + w_2 f_{admet}(\boldsymbol{x}) + w_3 f_{synth}(\boldsymbol{x}) - w_4 Penalty(\boldsymbol{x})$$

其中，Penalty(x)用於處理必須避免的硬性條件（例如：明顯毒性警訊、或免疫原性風險過高），權重 w_i 會依示範標靶與 MOA 需求調整。上述 J(x)的設定提供一個「可工程化量測」的基準；後續年度將引入子計畫 4 的 PBPK/QSP 回饋作為額外的目標項，使設計端能直接朝臨床推論所需的條件收斂。

為確保後續年度的模型與流程改進可以被嚴格比較，本年度亦將建立一套一致的基準評估方法。在效能面，將以端到端時間（從匯入子計畫 2 資料、生成候選、評分、去風險到輸出候選套件）與 GPU/CPU 資源占用為主軸，並同步納入能耗指標，連結節能減碳與可落地性。在品質面，將以候選排序的合理性（例如：與文獻已知構效關係是否一致）、去風險篩選的偵測率（例如：能否提前標記高毒性或高免疫風險候選）、以及候選多樣性（避免過度集中在單一局部最適）為主要指標。此外，針對 Docking、ADMET、免疫原性與合成可行性等工具模組，本年度將測試替換/移除的比較，以釐清各評分模組對最終候選選擇的邊際貢獻，並形成第二年動態最佳化掃描的去風險策略設計依據。

同時，本年度也會針對「長序列」負載 Profiling。做法是把子計畫 2 之證據表、標靶序列/結構描述、以及設計端的推論紀錄分別量化其長度分布（例如：Token 數、檔案大小、候選數與候選歷史深度），並以標準 Transformer attention 作為對照，量測在 FP32 與 FP16/BF16 下的記憶體占用、運算時間與數值誤差累積。Profiling 結果將在第二年導入 PSOS 前形成明確的瓶頸定位與量化目標，使注意力效率的研究被自然地嵌入藥物最佳化主軸之中，而非另立題目。

本年度結束時，子計畫 3 預期可產出一套可送入子計畫 4 的候選分子套件：包含候選變體庫 (至少數百個候選) 、其結構檔（SDF/PDB）、結合與 ADMET/免疫風險之摘要表、以及可解釋訊息（例如候選變更位置的 Attention map/熱點投影）。在工程上，亦將建立每輪計算時間、資源使用與能耗量測方法，作為後續導入 PSOS 前的效率基準。

（二） 第二年：親和力/選擇性最佳化與可解釋設計，並在瓶頸處導入 PSOS 提升長序列效率

第二年的重要性在於從「能跑」邁向「更準、更有理由」。若 Designer Agent 只會大量枚舉並用單一分數排序，容易在審查與實作上被視為缺乏研究深度；因此本年度的核心是建立可解釋的親和力/選擇性最佳化流程，並把設計假設具體化到結構層級（例如：特定核心功能域的作用面) ，同時把計算效率議題自然地放回藥物設計情境中處理。

首先，本子計畫核心引擎明確落在材料所描述的「AI-Physics Hybrid Optimization」與「Dynamic Optimization Scan」。具體作法是：以第一年建立的 Docking /能量評分流程作為基準，逐步導入更細緻的結構評分，例如在候選與標靶複合體上做局部構形鬆弛（Relaxation）與能量最小化，以減少 Docking 造成的幾何偏差；對於胜肽候選，將以 Deep mutation scanning

的概念在序列空間系統性探索，將「哪些胺基酸位置的改動」與 「結合面形狀/電荷分布改變」建立對應，並與 MOA（例如抑制或中和）需求連結。此過程亦會把選擇性納入評估，例如在可能的 Off-target（非預期標的）上做對照 Docking/相似度評分，形成避免副作用的早期訊號。

在動態最佳化掃描的演算法設計上，本年度將把「候選生成」與「候選評分」明確拆成兩層：生成層以可修飾位置清單為搜尋空間，針對胜肽序列以單點/多點突變、片段替換或保守替換等策略提出候選。評分層則以結構與物理訊號為主（Docking 分數、能量最小化後的穩定度、互作指紋相似性、氫鍵/鹽橋網路的保留與增強），並將動力學資訊（例如 k_on/k_off 或 SPR 推回的結合動力學趨勢）納入次要但關鍵的排序因子。在搜尋策略上，將以強化學習或貝氏最佳化等方式把多目標評分整合為可更新的策略，使 Designer Agent 能在有限計算預算下快速收斂到少量高潛力候選。為與生醫目標 3 流程圖之 Kinetic Data / Biophysical Constraints 對齊，評分層除結合能量指標外，亦將把動力學相關資訊（K_d、k_on、k_off、ΔG、IC50 及其量測條件）整理為 kinetic_table 欄位並納入評分/排序；同時把生物物理限制（例如可接受之濃度窗、聚集風險上限、免疫風險門檻等）整理為 constraint 欄位，使最佳化不只追求「黏得更緊」，也能在開發性與安全性上維持可行。

為兼顧速度與可信度，本年度將採取「分層近似」的計算策略：在大量候選的初步掃描階段，以快速 Surrogate（例如：較輕量的結構預測、以互作指紋近似的構型評分、或以統計模型近似的動力學趨勢預測）先把候選空間縮小；對於少量進入前段的候選，再逐步啟用較高成本但較高準確度的計算（例如：較長步數的分子動力學模擬、或更細緻的自由能近似），以降低誤判風險。在此過程中，若發現模型需要同時保留較長的設計上下文（例如：多輪候選歷史、結構描述與限制條件）才能做出穩定判斷，則第二年亦將完成 PSOS 的原型實作與基準比較，確認其在 FP32 下對長序列 Attention 的記憶體占用與速度優勢，並把它整合到設計端需要長上下文的推論步驟中，作為後續年度大規模運作的基礎。

本年度同時強化可解釋性輸出，使設計端不只是給排名，而是能交代「為何這些變更有意義」。除了沿用 Attention map 與 SHAP [31]的貢獻分解外，本子計畫將建立把重要特徵回投到 3D 結構表面的視覺化流程，讓研究者可以在 PAI-1 的結構上看到可能的作用熱點，以及候選變更如何改變作用面。此一設計可直接支援子計 4 假設 QSP 設定（例如假設抑制 PAI-1 後 TGF-β 路徑動態抑制比例），也能讓後續實驗設計更聚焦。

在效率面，本年度將先以第一年量測得到的基準，辨識哪些步驟出現長序列或大量候選造成的延遲。實務上，長序列並不只來自蛋白質序列長度，也常來自多模態證據拼接：例如把子計畫 2 的多張表格、文獻摘要與結構描述整合為可驗證報告時，輸入上下文可能遠超過一般模型的舒適範圍；此外，當候選變體庫擴大到數千等級，批次化推論也會放大 Attention 模組的成本。子計畫 3 中會出現長序列（Long token）或大量候選的情境包含：蛋白質序列較長（例如數百個胺基酸）、結構描述（PDB/SDF）在文字層級可達數千行，以及把子計畫 2 的多來源證據表格與文獻摘要拼接成可驗證報告時，輸入上下文可能快速變長。若採用 Transformer 類模型，核心運算為 scaled dot-product attention [19]，可寫為：

$$Attention(Q,K,V) = Softmax\left(QK^T/\sqrt{d}\right)V$$

在上述情境中，資料精度會直接影響候選排序與決策。以本文前述結合自由能 ΔG 與解離常數 Kd 之關係為例，在室溫條件下，約 1.36 kcal/mol 的 ΔG 即可能對應到約 10 倍的 Kd 差異；因此，若 Attention 計算因 FP16/BF16 量化或長序列累積誤差而改變少量 logit，同一組候選的相對排名就可能產生變化，進而影響後續子計畫 4 之 PBPK/QSP 參數化與實驗優先順

序。現行 FlashAttention 等注意力加速方法，在實務上多以 FP16/BF16 kernel 與 Tensor Core 取得主要效能，當工作負載需要維持 FP32（例如需要穩定比較細微能量差、或在長序列下避免 Softmax 的下溢/上溢）時，往往難以維持相同量級的加速收益。基於此，子計畫 3 將 PSOS 定位為 Designer Agent 的工程基底：在不改變 Exact attention 語意的前提下，提供可在 FP32 下運作、且記憶體需求近似線性成長的注意力計算，使整體藥物最佳化流程同時具備可計算性與高精度。

另一方面，Designer Agent 在整合子計畫 2 輸入與設計歷程時，確實存在長序列、長 token 的計算需求。以蛋白質/胜肽序列及其結構標註為例，單一標靶往往需要同時保留序列、核心功能域註記、可修飾位置清單與多個突變候選；再加上 PDB、SDF 等結構檔案本身即屬於長文本格式，若要讓模型在設計時同步參考受體結構周圍殘基、候選構型、文獻證據摘要與動力學、生物物理限制條件，輸入上下文就會快速增長。當此流程進入多輪迭代並需要保留可驗證的設計依據與推論紀錄時，整體上下文往往超出一般注意力加速假設的長度範圍，因此注意力效率與記憶體占用會直接左右是否能在合理時間內完成候選排序與去風險評估。

$$Attention(Q,K,V) = Softmax\left(QK^T/\sqrt{d}\right)V$$

其中，Softmax 是計算注意力權重的關鍵。當序列長度增加時，attention 的計算與記憶體成本會迅速上升，即使採用 FlashAttention 等技術降低記憶體需求 [21]，但高度仰賴 Tensor core 的 FP16/BF16 使其些微精度下降，對於多數任務尚可接受，然而，科學計算如分子組合，其各種特徵數值敏感性遠高於多數常見的影像或文字任務。因此，高精度 FP32 底下的加速機制目前尚有距大缺口。子計畫 3 提出 PSOS（Prefix-Scan Online Softmax）作為支援性方法：在不改變 Softmax 精確結果的前提下，把 Softmax 的關鍵累積量改寫為可用 Prefix-scan 平行化的形式，並支援逐段（Online) 處理。以一維分數序列 s_j 為例，可用穩定化（避免溢位）的遞迴寫法累積最大值與規範化常數：

$$m_j = max\left(m_{j-1}, s_j\right), l_j = l_{j-1} \cdot exp\left(m_{j-1} - m_j\right) + exp\left(s_j - m_j\right)$$

並進一步把加權向量和一併累積（以 v_j 表示被加權向量）：

$$w_j = w_{j-1} \cdot exp\left(m_{j-1} - m_j\right) + exp\left(s_j - m_j\right) \cdot v_j, y = w_n/l_n$$

上述 (m_j, l_j, w_j) 可視為可結合（Associative）的狀態，能以 Prefix-scan 在 GPU 上降低序列方向的依賴深度，提升長序列處理的吞吐量。PSOS 在本子計畫中的使用方式是「定位瓶頸→置換對應 Softmax 子程序→以同等輸出一致性驗證→量測速度/能耗」；其目的是把計算效率提升轉化為藥物設計流程的實際產能，而非另起一個與藥物無關的研究主線。

本年度將在確定瓶頸位置後，把 Attention 的 Softmax 子程序以 PSOS 方式改寫，並以「輸出一致性」與「速度/能耗」雙指標驗證其有效性；換言之，PSOS 在本年度的價值是讓 Designer Agent 在高吞吐量情境下仍能維持高精度評分與可解釋輸出。

本年度結束時，本子計畫預期可完成：一套可解釋的親和力/選擇性最佳化流程、在 PAI-1 案例上具體呈現一批較先導分子更具潛力的候選集合、以及在長序列/大量候選情境下的效率提升與能耗量測報告。這些成果將成為第三年把 子計畫 4 回饋正式納入設計更新的前提。

（三）第三年：多參數風險降低與 子計畫 4 回饋驅動更新，形成可反覆迭代的設計策略

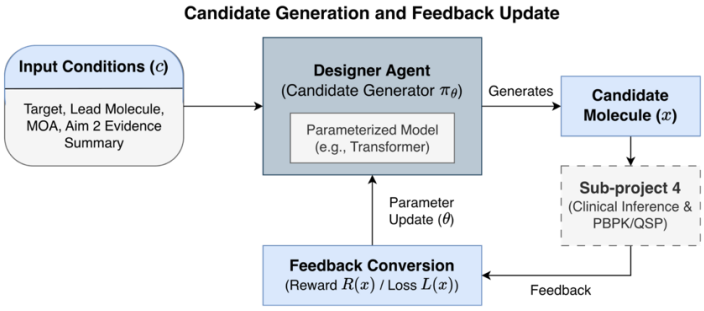

圖五、回饋驅動更新之設計策略

第三年的重要性在於把 Designer Agent 從「結構與分數導向」推進到「臨床推論導向」。在前兩年，本子計畫將建立可解釋的結合/選擇性最佳化與早期 ADMET 篩選；然而，真正決定候選是否有機會走到人體試驗的是暴露量、作用濃度與路徑動態等整體系統行為。子計畫 4 以 PBPK/QSP 模擬提供的回饋，正是把分子設計連結到臨床假設的關鍵，因此本年度的研究主軸是把 子計畫 4 的回饋結構化地納入設計更新，形成可反覆迭代的設計策略，如圖五所示。

首先，本子計畫將候選分子套件擴充為「可直接參數化 PBPK/QSP」的版本，包含分子層級必要的物化性質摘要（例如：分子量、logP、pKa、血漿蛋白結合率的預測或文獻值）、以及與 MOA 對應的作用假設欄位（例如預期抑制核心功能域後的有效抑制比例）。子計畫 4 回饋的內容則將以固定欄位回寫到本子計畫，例如：在特定族群條件下的濃度–時間曲線是否達到有效濃度區間、QSP 模型下游路徑抑制的動態百分比是否足夠、以及毒性相關風險是否升高。此一介面定義的目的，是讓回饋不再停留在文字敘述，而能被轉換成 R(x) 或 L(x) 的量化項，進一步用於候選產生器 π_θ 的更新（見第五節之公式） 。

為了讓 PBPK/QSP 的回饋能真正「驅動更新」，本年度將建立一套可機器讀取的回饋規格，將子計畫 4 輸出的濃度–時間曲線、有效暴露窗、下游路徑抑制動態百分比與毒性警訊等訊號，轉換成可直接寫入設計目標函數的量化指標。例如：本計畫將把「是否達到有效濃度區間」寫成連續化的 Margin（距離目標窗的偏離量），把「下游路徑抑制是否足夠」寫成期望動態曲線與實際曲線的差異度量，並把毒性警訊寫成約束違反的懲罰項。如此可避免回饋僅停留在文字敘述，使更新步驟可以在同一個數學框架下被明確追蹤與檢核。具體來說，Designer Agent 內部的「候選產生器」可視為一個參數化模型 π_θ（例如：以 Transformer 為核心的序列生成模型或結構生成模型），在給定條件 c（標靶、先導分子、MOA、以及子計畫 2 證據摘要）下產生候選 $\boldsymbol{x}$。當子計畫 4 回饋臨床推論結果後，子計畫 3 將把回饋轉換成獎勵 R(x) 或損失 L(x)，並用以更新 θ，使後續產生的候選更符合目標。其典型形式可表示為最大化期望獎勵：

$$max_\theta E_{x\sim\pi_\theta(\cdot|c)}[R(x)]$$

若採用策略梯度 (policy gradient) 形式，則一次更新可寫為：

$$\theta \leftarrow \theta + \eta(1/K)\Sigma_{k=1}^{K} R(x_k)\nabla_\theta log\pi_\theta(x_k)$$

其中 η 為學習率，K 為一次取樣的候選數量。子計畫 3 不預設一定要使用特定強化學習演算法，而是採取「先用 Baseline 的候選生成與重排序策略建立可執行流程，再逐步引入可微分/可學習的更新規則」的路線，以確保研究主軸仍以藥物最佳化為核心。

在驗證面，本年度將把計算結果轉譯成可操作的實驗優先順序與量測建議，並與生醫團隊共同形成回饋機制。以結合動力學為例，對於預期在 PBPK 模擬下可維持有效暴露窗的候選，將優先安排 SPR 或等效的生物物理量測以取得 k_on/k_off，並據此回寫到設計端的動力

學約束；對於免疫風險較高或聚集傾向較明顯的候選，則優先在細胞模型量測免疫標記、細胞毒性與聚集相關指標，以降低動物試驗成本並加速淘汰高風險變體。此一策略使子計畫三不僅輸出「分數」，而是把實驗資源配置與資料回饋視為整體最佳化的一部分，提升研究落地的可行性。此段工作對齊生醫目標三流程圖之 Experimental Validation：細胞模型用於療效（Target activity）、毒性與免疫相關指標的早期篩檢；動物模型用於藥效（例如腫瘤體積、存活）與體內安全性及 ADMET 之驗證，並把量測結果回寫到子計畫三的動力學與去風險約束中。

在方法上，本年度將把「多參數降低風險」做得更完整。一方面，ADMET/毒性模組將從第二年的評分擴展為多任務校準：針對 Tox21 任務[32]與 ADMETlab 2.0 [29]的多項指標，建立一致的尺度化與不確定性估計，避免單一模型偏差導致錯誤篩選；另一方面，胜肽/蛋白質候選將把免疫原性風險（NetMHCpan [30]）與聚集風險納入更嚴格門檻，並評估常見延長半衰期策略（例如：PEG 修飾；在分子上接上聚乙二醇以增加體內停留時間）對結合面與免疫風險的影響，使候選在「有效」之外也「比較有機會被開發」。此一「多參數降低風險」設計將直接對應生醫目標三流程圖之 Multi-Parameter De-risking（Immunogenicity、Aggregation），並把 ADMET/毒性作為同層級去風險指標一併納入，確保候選在進入細胞/動物實驗與子計畫四臨床推論前，已完成第一輪可量測且可驗證的風險篩選。

驗證策略同樣重要。本年度將強調與實驗資料的對接。對於候選分子，子計畫 3 將與整體計畫的細胞或動物實驗結果建立對照，並視情況納入離體 (ex vivo；在生物體外取出的組織或細胞環境中) 資料作為中介驗證 (if any)，使模型更新不僅依賴純計算結果。此一設計可降低模型在真實生物系統中的落差，並為第四年的整合示範累積可信的證據鏈。本年度結束時，本子計畫預期能形成一個可反覆執行的「設計→PBPK/QSP 推論→回饋→更新」流程，並在 PAI-1 案例上完成至少數輪迭代，產出一組在結合、ADMET 與臨床推論條件上都較為均衡的候選集合。這將直接支援第四年的平台化整合與展示。

（四）第四年：端到端整合與平台化部署（k3s＋n8n），完成示範案例與可移植規格

第四年的重要性在於把前三年的方法真正整合成可運作的平台，並以示範案例呈現「從子計畫 2 證據到子計畫 4 臨床推論」的端到端成果。對工程智慧計算領域的審查而言，若缺乏可部署、可維運、可重複執行的系統設計，研究很容易被視為停留在概念或單次實驗；因此本年度將以平台化為主軸，建立可在研究環境長期運行的代理互動架構，並以 k3s 與 n8n 形成可重複執行的工作流程。在系統架構上，本子計畫將以 k3s（輕量化 Kubernetes）建立 GPU/CPU 混合叢集，將 子計畫 2–子計畫 4 的核心服務與工具（例如：Docking、CHARMM、ADMETlab 2.0、NetMHCpan 以及 PSOS 加速模組）以容器化方式部署，並建立共用資料層與版本紀錄，確保每一次設計迭代的輸入、候選集合與結果都能被驗證。工作流程層則以 n8n 建立可視覺化的任務編排：包含以條件分支決定是否進入下一輪設計、在風險指標達到門檻時自動通知研究者、以及在計算資源不足時排程與佇列管理，建立研究環境中可長期運作的可重複執行研究流程。

在硬體與運算資源規劃上，本年度將把前三年的計算模式落實為可長期運作的配置。本子計畫預期同時存在兩類主要負載：其一為結構/物理工具鏈（Docking、能量最小化、少量高精度模擬）偏向 CPU 與中度 GPU；其二為序列/結構模型與長上下文推論偏向 GPU，且因精度需求必須穩定提供 FP32。因此，本計畫將採 GPU/CPU 分層架構：以 k3s 在同一叢集內管理 GPU 節點與 CPU 節點，GPU 節點負責模型推論與 PSOS attention 核心，CPU 節點負責批次結構前處理與工具型任務；並配置共享高速儲存保存候選庫、模型版本與設計歷史，同

時以監控機制持續追蹤吞吐量、顯存占用與能耗。此規劃可使平台在規模擴大時仍能以增添節點的方式線性擴充，而不需重寫流程。

此外，本年度將完成從研究到落地所需的工程化驗證：包括端到端回歸測試（固定輸入時候選排序與報告內容應一致）、資料版本與模型版本的一致性檢核、以及故障情境下的復原流程（例如：計算節點短暫離線、單一工具失敗時的重試與警告）。n8n 的工作流程亦會與資料層的版本紀錄綁定，確保每一次迭代都有可驗證的執行紀錄與輸入輸出對應。最後，本年度將把平台化規格整理成可移植的文件與範例專案，使其可在其他癌別/標靶情境重用，並作為後續大型計畫或產學合作的基礎。

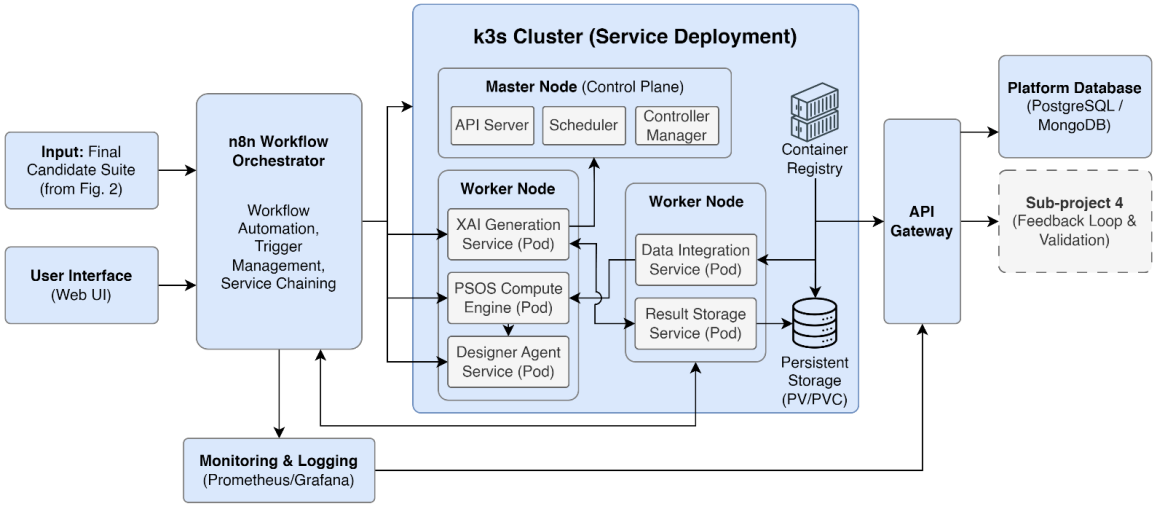

圖六、第四年平台化整合：以 k3s 叢集部署服務，並以 n8n 編排工作流程之架構示意圖

在整合示範上，本子計畫將以胰臟癌 PAI-1 案例完成多輪迭代，並把每一輪迭代的設計決策以可驗證報告呈現：包含候選分子結構、結合/選擇性與 ADMET/免疫風險分數、子計畫 4 的 PBPK/QSP 推論摘要、以及回饋後的設計修正方向。對於審查所關切的工程指標，本年度也將系統性回報整體吞吐量、平均每輪迭代所需時間、以及在不同算力配置下的能耗差異，並驗證 PSOS 在長序列情境下對平台穩定性與效率的實際效益。

本年度結束時，子計畫 3 的貢獻將包括：一套可在研究機構內部部署的 AI 藥物最佳化平台（Designer Agent），其設計端能與臨床推論端（子計劃 4）協作並反覆迭代；一套可移植到其他癌別/標靶的資料格式與流程規格；以及在工程智慧計算方法上，證明 PSOS 等高效率 Attention 方法如何作為藥物設計平台的支援技術，讓高精度模型在實務上可被長期使用。

子計畫 4：AI 驅動之虛擬臨床試驗評估與決策中樞

一、研究目的

（一）胰臟癌藥物開發的困境與 PAI-1/LRP1 軸線之機會

胰臟癌被稱為「癌中之王」，其五年存活率長期低於 10-12%。主要原因在於其緻密的結締組織增生（Desmoplasia）形成獨特的腫瘤微環境（TME），阻礙化療藥物（例如：Gemcitabine）的輸送。成大醫院沈延盛醫師團隊的先導研究（Theranostics, 2019）證實，PAI-1（Plasminogen Activator Inhibitor-1）不僅是凝血因子，更是調控腫瘤微環境纖維化的關鍵。PAI-1 透過 LRP1 受體活化胰臟星狀細胞（PSCs），促進膠原蛋白堆積與 IL-8 分泌，進而導致化療抗藥性。[5]因此，本計畫旨在運用嶄新 AI 技術架構開發能阻斷 PAI-1/LRP1 結合的胜肽藥物，作為突破胰臟癌治療瓶頸的新策略。

（二）傳統臨床試驗設計的盲點與數位轉型需求

傳統藥物研發從動物實驗直接跳躍至人體試驗（From Bench to Bedside），往往忽略了物種間的生理差異以及病人族群的高度異質性。在 PAI-1 抑制劑的開發歷史中，雖有多款小分子曾進入臨床，卻因出血風險管控不當或未能篩選出「纖維化依賴型」的次族群而失敗。此外，缺乏系統性的劑量模擬，導致臨床二期常因劑量不足（無效）或過高（毒性）而終止。「虛擬臨床試驗（In Silico Clinical Trial）」技術雖已被 FDA 認可，但現有方案多為單點工具，例如：僅做 Pharmacokinetics（PK）模擬，缺乏整合性。本計畫之目的即在於解決此缺口，建構一套能像資深臨床試驗主持人（PI）般，綜合考量藥動、藥效、法規與臨床實務的 AI 決策中樞。

（三）獨特利基：在地化 RWD 數據驅動之數位孿生平台

本計畫之核心競爭力在於數據的不可替代性與在地化校準，儘管目前已有公開資料庫（如 TCGA [40]），但缺乏針對台灣本土基因特徵的系統性驗證，常導致模型預測失準。本計畫深度整合國立成功大學沈延盛醫師團隊獨家擁有之 PAI-1 高表現胰臟癌臨床世代資料，包含詳細病理機制數據、長期存活追蹤及血漿生物標記。這使本計畫能夠利用在地化真實世界數據（Real World Data, RWD）進行貝氏校準，精確模擬台灣病患之藥物反應，建立世界首個針對 PAI-1 標靶之「數位孿生（Digital Twin）」預測平台，將藥物開發風險於 In Silico 階段大幅降低 [40, 41]。

（四）核心解方：建構具備臨床推理之多代理人決策系統（Council of Agents）

為實現上述目標，本計畫將開發具備「臨床推理（Clinical Reasoning）」能力的 Orchestrator Agent。核心採用 NVIDIA Nemotron-3-Nano-30B-A3B 模型 [6]，以多代理（Multi-Agent）架構協調三個專業子代理，組成「虛擬委員會（Council of Agents）」 [36]：

1. **生理藥動學子代理（PBPK Sub-agent）**：負責藥物體內動態模擬。
2. **定量系統藥理學子代理（QSP Sub-agent）**：負責藥效機制與生物標記連結。
3. **因果分層子代理（Causal Stratification Sub-agent）**：負責病患亞群之因果推論與篩選。

工程團隊將實作自動化 pipeline，即時查詢 FDA/TFDA 法規資料庫與 ADMET-AI 毒理預測模型 [38]。系統最終將產出具備「思考鏈（Chain of Thought）」之**虛擬臨床試驗建議書（Final Clinical Trial Suggestions）與結構/劑量優化提示（Dose/Structural Hints）**，並回饋至上游藥物設計子計畫 3，形成閉環優化，解決過往轉譯成功率低落的關鍵痛點 [12]。

二、研究目標

本子計畫旨在建構一個「全自動化、具備臨床推理能力的虛擬試驗評估平台」，具體目標如下：

（一）建構多代理協作架構（Multi-Agent Architecture）：開發以 Orchestrator 為首的層級化 AI

系統，指揮 PBPK（生理藥動）、QSP（系統藥理）、Calibration（族群校準）三個子代理協同運作 [12, 36]。

（二）**整合異質性生醫模擬引擎：**協助生醫團隊將 PK-Sim®、MoBi®等專業模擬軟體封裝為可被 AI 呼叫的 API 服務，並建立統一的資料交換標準 [34]。

（三）**實作外部知識檢索與法規對齊：** 訓練 AI 主動查詢 ADMET-AI（毒理預測）、FDA/TFDA 藥品資料庫，確保虛擬試驗設計符合現行法規與安全標準 [33, 40]。

（四）**產出可解釋之決策報告：** 綜合模擬結果，自動生成包含「最終臨床試驗建議（Final Clinical Trial Suggestions）」與「劑量/結構優化提示（Dose/Structural Hints）」的決策報告，回饋予子計畫 3 進行藥物再設計 [12, 35]。

三、分年研究內容與方法

本計畫將以四年為期，循序漸進地構建「AI 驅動之虛擬臨床試驗平台」。整體策略採取「先建模、後連結、再智慧化、終驗證」的路徑，確保每一階段的產出皆具備可驗證性。

（一） 第一年：PBPK 自動化模擬平台建置與毒理預測子代理人開發

目標：完成藥物動力學（PK）的數位化基礎建設，實現單點工具的 API 化與自動化推論。

1. **建置 PBPK 自動化模擬平台（PBPK Automation Pipeline） [34]**
   - **(1) 核心技術：**利用 Python 封裝 PK-Sim®、MoBi®的 Command Line Interface（CLI）功能，開發自動化腳本。
   - **(2) 實作內容：** 建立標準化輸入介面（接受 MW, LogP, pKa, Solubility 等理化參數），自動生成個體化生理參數檔案（.xml），並批次執行運算。
   - **(3) 產出：** 能夠在無人值守下，針對單一化合物快速產出腫瘤組織濃度（Ctumor）、血漿濃度曲線（AUC）與組織滯留時間（MRT）。
2. **開發與部署 Sub-agent 1（Physiological Agent）**
   - **(1) 封裝技術：**將上述 PBPK 流程封裝為 Docker 容器，並透過 RESTful API 開放服務。
   - **(2) 模型校準：**導入 NCKU 提供的 PAI-1 抑制劑歷史 PK 數據，針對胰臟癌病患特殊的生理參數（如胰臟血流量減低、纖維化組織滲透率）進行模型參數優化，完成 Sub-agent 1 的基礎訓練。
3. **建立 ADMET-AI 與法規資料庫在地推論管道（Local Inference Pipeline） [38]**
   - **(1) 毒理預測：**在地端工作站部署開源 ADMET-AI（基於 Graph Neural Networks, GNNs），針對 hERG 心臟毒性、肝毒性（DILI）與口服生物利用率進行高通量篩選。
   - **(2) 法規資料庫串接：**建立自動爬蟲系統，定期抓取 FDA/TFDA 公開審查報告，建立結構化的 SQL 資料庫，供後續查詢比對。

（二） 第二年：QSP 系統藥理平台建置與 PK-PD 鏈結模型開發

目標：完成藥效動力學（PD）的機制模擬，並打通 PK 與 PD 之間的數據斷點，形成連動模擬。

1. **建置 QSP 自動化模擬平台（QSP Automation Pipeline） [39]**
   - **(1) 核心技術：**整合 MoBi®與 SABIO-RK 動力學參數資料庫，建構 PAI-1/LRP1 訊息傳導路徑的常微分方程（ODE）模型。
   - **(2) 實作內容：**模擬 PAI-1 與 LRP1 結合後對下游 p-Smad2/3 路徑的活化影響，以及對細胞外基質（ECM）堆積的動態調控。

2. **開發與部署 Sub-agent 2（Mechanistic Agent）**
   (1) **功能實作：**將 QSP 模型封裝為 Agent，使其能接收上游 PK 數據（如藥物在腫瘤微環境的濃度），計算標靶佔據率（Target Occupancy, RO%）。
   (2) **參數優化：**利用已知的 PAI-1 結合親和力（Kd）數據，校正 QSP 模型中的結合速率常數（kon/koff）。
3. **建立 PK-PD Link Model 與子代理通訊機制**
   (1) **連結模型：**開發「PK-PD Linker」中間件，將 Sub-agent 1 輸出的「隨時間變化之腫瘤濃度」直接映射為 Sub-agent 2 的「輸入函數（Input Function）」。
   (2) **通訊協定：**定義 Sub-agent 1 與 Sub-agent 2 之間的 JSON 資料交換標準，實現「藥物進入→濃度分佈（PK）→標靶結合（PD）→療效預測」的自動化序列串接。

（三）第三年：因果推論與虛擬族群建構（端對端 Pipeline 整合測試）

目標：引入真實世界數據（RWD），建構數位孿生族群 [14]，並在不依賴 AI 決策的情況下，完成全流程的「硬編碼 (Hard-coded)」串接測試。

1. **開發 Sub-agent 3（Causal Stratification Agent）與虛擬族群建構**
   (1) **數據整合：**深度整合 **NCKU PAI-1 臨床世代數據（Clinical Cohort）**、在地多體學數據（Local Multi-omics）與 TCGA 公開資料庫 [40]。
   (2) **虛擬族群（Virtual Cohort）生成：**利用統計生成技術，創建第一批與台灣胰臟癌病患特徵高度一致的虛擬受試者（包含年齡、性別、基因型、共病症等分佈）。
   (3) **因果推論：**實作因果森林（Causal Forest）演算法，計算個體化治療效應（Individual Treatment Effect, ITE）。
2. **全流程管線串接與統一測試（End-to-End Pipeline & Unified Testing）**
   (1) **硬編碼腳本（Hard-coded Scripting）：**暫不啟用 Orchestrator 的 AI 自主決策功能，改以固定腳本控制流程。
   (2) **流程驗證：**執行 Sub-agent 1（PK）→ Sub-agent 2（PD）→ Sub-agent 3（Causal）的完整數據流測試。
   (3) **產出：**生成第一批虛擬臨床試驗結果，包含不同劑量下的族群層級反應分佈（Population-level Response Distribution）與 ITE 分數，確立數據 Pipeline 的穩定性與正確性。
3. **專家決策軌跡收集與 SRL 啟動 [9]**
   (1) **數據收集：**記錄成大沈延盛醫師團隊等臨床專家在面對複雜病例時的決策過程（例如：看到血小板低下時如何調整劑量、看到特定基因突變時如何篩選收案條件）。
   (2) **SRL 準備：**將上述專家決策轉化為「狀態-行動-獎勵（State-Action-Reward）」的訓練數據集，啟動監督式強化學習（Supervised Reinforcement Learning）的初步訓練。

（四）第四年：Orchestrator 智慧化與虛擬試驗系統驗證

目標：賦予系統「大腦」，透過 SRL 學習專家思維，並進行嚴格的真實世界數據驗證（Sim vs. Real），產出具 IND 申請水準的報告。

1. **Orchestrator 的 SRL 優化與臨床推理模型完成**
   (1) **模型訓練：**利用第三年收集的專家軌跡，對 NVIDIA Nemotron-3-Nano 模型 [6] 進行完整的 SRL 微調（Fine-tuning）。

(2) **智慧決策：**訓練 Orchestrator 能根據 FDA/TFDA 指引、臨床試驗設計規範與 PAI-1 領域知識，綜合判斷三個子代理的輸出，動態調整模擬參數（如建議修改收案標準以排除高風險族群）。

2. **產出可解釋性推論日誌（Explainable Reasoning Logs）**
   (1) **功能實作：**系統需具備「思考鏈（Chain-of-Thought）」輸出能力，能自主產出包含收案條件（Inclusion / Exclusion Criteria）、最佳劑量建議、潛在風險評估的完整決策日誌。
   (2) **透明化：**每一項建議皆須標註引用來源（例如：引用 PK-Sim 模擬結果或 FDA 指引第幾條），消除 AI 幻覺疑慮。
3. **虛擬試驗 vs. 真實世界數據（Sim vs. Real）交叉驗證**
   (1) **回溯性驗證：**將系統預測的 PAI-1 抑制劑存活曲線，與成大醫院歷史臨床資料進行比對（Cross-check）。
   (2) **一致性確認：**驗證虛擬試驗結果與真實數據的高度一致性（統計顯著性），證明平台具有預測真實臨床結果的能力。
4. **產出轉譯決策報告（Translational Decision Report）**
   (1) **最終成果：**系統自動生成具備專家認可水準的完整報告，內容涵蓋臨床試驗設計書（Protocol Synopsis）與風險緩解策略。
   (2) **價值證明：**證明本平台所生成之建議具備 IND（Investigational New Drug）申請前評估的科學可信度，完成系統的穩健性（Robustness）與可靠度（Reliability）總體測試。

（四）預期完成之工作項目及成果。請填列年度目標及預期成果表，請列述下列項目：1.預期完成之工作項目。2.對於參與之工作人員，預期可獲之訓練。3.預期完成之研究成果（如實務應用績效、期刊論文、研討會論文、專書、技術報告、專利或技術移轉等質與量之預期成果）。4.學術研究、國家發展及其他應用方面預期之貢獻。

一、預期完成之工作項目

下方條列各子計畫預計完成項目之甘特圖：

（一）第一年度

工作項目	2026 Q3	2026 Q4	2027 Q1	2027 Q2
子計畫 1				
共通資料標準化建構平台開發－臨床數據整理				
共通資料標準化建構平台開發－多體學與資料庫資料格式標準化與結構整理				
單核苷酸多態性 (SNP)分析平台開發－全基因體關聯性 (GWAS)分析				
單核苷酸多態性 (SNP)分析平台開發－Post-GWAS 分析 (功能註解、精細定位、全轉錄組關聯分析等)				
全外顯子定序 (WES)分析平台開發－遺傳變異分析與註解、ExWAS 分析系統化				
整合 AI 平台開發				
子計畫 2				
「生物資訊與統計分析子代理人(A1)」證據檢索 API 工具模組化實作				
「標靶證據解讀與信心評分子代理人(A2)」: 基於「A1：基因體層級之表型關聯結果」資料彙整與評分流程設計與實作				
子計畫 3				
完成自子計畫 2 接收標靶證據、先導分子與疾病情境之自動化匯入與格式清洗流程。				
整合 AlphaFold/ESMFold 與 AutoDock Vina 建立自動化結構預測與結合力評分基準管線。				
建立胜肽與小分子之變體生成器，並整合 ADMETlab 2.0 與 NetMHCpan 初步去風險篩選。				
子計畫 4				
建立並完成 PBPK 自動化模擬平台，整合 PK-Sim® 之批次模擬流程，形成可重複執行、可追蹤之藥動學推估管線，支援不同候選分子與物種條件之快速模擬。				
建立 ADMET-AI 本地端推論服務與 FDA/TFDA 法規資料庫自動化檢索系統，產出首批候選分子之毒性、藥物動力學風險評估與法規對照數據				
完成生理藥動學子代理（Sub-agent 1） 之建置與參數校準，利用 NCKU PAI-1 臨床試驗數據進行在地化參數修正				
形成穩定之「候選分子 →PBPK 模擬 →PK 預測」資料流，奠定後續藥效與臨床推論模組整合之基礎。				

（二）第二年度

工作項目	2027 Q3	2027 Q4	2028 Q1	2028 Q2
子計畫 1				
全外顯子定序 (WES)分析平台開發－遺傳變異分析與註解、ExWAS 分析系統化				
單細胞 RNA 定序 (scRNA-seq)分析平台開發－基因表現矩陣與細胞類型表現特徵建構				
單細胞 RNA 定序 (scRNA-seq)分析平台開發－細胞基因共表達網絡、發育軌跡與溝通分析				
RNA 定序 (bulk RNA-seq)分析平台開發－差異表達基因分析				
RNA 定序 (bulk RNA-seq)分析平台開發－基因共表達網絡與生物途徑分析				
蛋白質體 (proteome)分析平台開發－差異表達蛋白分析				
整合 AI 平台開發				
子計畫 2				
「藥理學與藥物化學證據檢索子代理人(A3)」PubMed、DrugBank 檢索 API 工具模組化、調用流程實作				
「藥物–標靶證據解讀與推論專家子代理人(A4)」基於「A3: 藥物資料庫檢索與彙整」資料彙整與評分流程設計與實作				
「主代理人」調用「子代理人」分析藥物-標靶-疾病治療潛力與不確定性流程設計與實作				
子計畫 3				
開發 Attention Map 與 SHAP 3D 熱點投影技術，提供候選分子結合關鍵區域之可解釋依據。				
導入動力學參數 (Kon/Koff) 與生物物理限制條件，建立 AI-Physics 混合式精細評分流程。				
於長序列推論瓶頸處導入 Prefix-Scan Online Softmax (PSOS)，實現 FP32 高精度下之線性記憶體加速。				
子計畫 4				
完成 QSP 自動化模擬介面：將 MoBi® 系統藥理模型參數化，建立藥物結合特性與下游訊號抑制效果之定量對應關係。				
建置並完成 系統藥理學子代理（Sub-agent 2）：使其能學習並模擬 PAI-1/LRP1 下游關鍵路徑。				
完成 PK–PD 連動模型（PK–PD Link Model）：開發 **PK-PD Linker 中間件**，使藥物暴露量、受體佔有率（RO%）與路徑抑制效果可於同一框架下整合推論。				
建立 Sub-agent 1（PK）與 Sub-agent 2（PD）之穩定串接機制：制定標準化資料交換協定 (JSON)，使候選分子之藥動與藥效推論可於系統層級連續運作。				

（三）第三年度

工作項目	2028 Q3	2028 Q4	2029 Q1	2029 Q2
子計畫 1				
全外顯子定序 (WES)分析平台開發－遺傳變異分析與註解、ExWAS 分析系統化				
單細胞 RNA 定序 (scRNA-seq)分析平台開發－基因表現矩陣與細胞類型表現特徵建構				
單細胞 RNA 定序 (scRNA-seq)分析平台開發－細胞基因共表達網絡、發育軌跡與溝通分析				
RNA 定序 (bulk RNA-seq)分析平台開發－差異表達基因分析				
RNA 定序 (bulk RNA-seq)分析平台開發－基因共表達網絡與生物途徑分析				
蛋白質體 (proteome)分析平台開發－差異表達蛋白分析				
蛋白質體 (proteome)分析平台開發－蛋白質交互作用網路分析				
整合 AI 平台開發				
子計畫 2				
「生物資訊與統計分析子代理人(A1)」基於「單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」調用模組流程設計				
「藥理學與藥物化學證據建模子代理人(A3)」CheMBL 檢索 API 工具模組化、調用流程實作				
子計畫 3				
整合 Tox21 毒性預測任務、聚集風險 (Aggregation) 與合成可行性評估，強化候選開發潛力。				
建立接收臨床推論參數 (如暴露量、路徑抑制率) 之介面，並將其轉化為模型更新之獎勵/損失訊號。				
依據生科團隊之細胞/動物實驗結果 (如 SPR, IC50)，回饋修正設計端之動力學約束條件並實作自動化				
子計畫 4				
完成 胰臟癌虛擬臨床族群（Virtual Cohort）之建置：整合成大醫院 **RWD 臨床資料**、在地多體學資料與 TCGA 公開資料。				
建立並完成 因果分層子代理（Sub-agent 3）：整合上述虛擬族群資料，利用因果森林 (Causal Forest) 等方法辨識高反應族群之關鍵特徵。				
完成端到端資料串接與聯合測試 (Hard-coded Pipeline)：在尚未導入 Orchestrator 自主決策的情況下，以腳本硬編碼串接 Sub-agent 1、2、3，驗證全流程數據通透性。				
產出第一批虛擬臨床試驗資料：包含個體化治療效應評分（ITE Score）與族群層級反應分布。				
啟動 SRL 訓練與專家軌跡收集：完成臨床專家決策流程的資料收集 (Expert Trajectories)，轉化為訓練集，正式啟動 Orchestrator 之 監督式強化學習 (SRL) 初步訓練。				

（四）第四年度

工作項目	2029 Q3	2029 Q4	2030 Q1	2030 Q2
子計畫 1				
蛋白質體 (proteome)分析平台開發－蛋白質交互作用網路分析				
整合 AI 平台開發				
子計畫 2				
「生物資訊與統計分析子代理人(A1)」基於「單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」調用模組流程設計與實作				
「標靶證據解讀與信心評分子代理人(A2)」：基於「A1：單細胞定序、轉錄體定序、蛋白體之標靶—臨床表型資料」資料彙整與評分流程設計與實作				
使用本地臨床資料微調子代理人提升系統表現				
子計畫 3				
將 Designer Agent 各模組與 PSOS 運算引擎容器化，並部署於 GPU/CPU 混合之 k3s 叢集。				
完成 PAI-1 完整迭代設計，輸出含結構、風險評估與臨床推論摘要之候選分子套件報告。				
完成平台能耗/效能基準測試報告，並建立可移植至其他癌別/標靶之系統規格文件。				
子計畫 4				
優化並完成 Orchestrator 與臨床推理模型：透過 SRL 學習 NCKU 專家黃金標準，並整合 FDA/TFDA 指引，使系統能綜合多子代理決策結果。				
建立具備「思考鏈」與可解釋推論日誌之框架：讓系統能自主產出包含引用來源之收案條件、劑量建議、風險評估。				
完成「虛擬臨床試驗 vs. 真實世界數據 (Sim vs. Real)」之交叉驗證：確認系統預測之存活曲線與成大醫院歷史臨床資料具高度一致性，驗證模型信效度。				
產出具專家認可水準之 轉譯決策報告（Translational Decision Report）				

以下條列各子計畫預計分年完成之項目：

子計畫 1：整合癌症多體學資料之標準化分析及證據化輸出建構平台

第一年預期完成項目：共通資料層完成與多體學分析平台雛型建立

1. 建立並完成共通資料標準化建構平台，產出標準化之癌症臨床主資料表、臨床表型定義與分層規則文件，並完成 Patient–sample mapping 與跨體學資料識別碼對齊機制。
2. 完成單核苷酸多態性（SNP）分析平台之核心功能建置，產出可重現之 GWAS 分析流程與標準化 GWAS summary statistics，作為後續 post-GWAS 與多體學整合之基礎輸入。
3. 於下半年完成全外顯子定序（WES）、Bulk RNA-seq 與單細胞 RNA 定序（scRNA-seq）分析平台之雛型 pipeline，包含基本資料前處理、品質控制與初步分析流程，使各平台具備可運作且可銜接共通資料層之初始能力。
4. 建立各分析平台之統一輸出格式、Metadata 描述與版本控管機制，確保後續年度之平台擴充與整合具一致基礎。

第二年預期完成項目：多體學分析平台功能擴充與協同運作

完成 WES 分析平台之功能擴充，穩定輸出高品質變異清單、功能註解變異表與基因層級彙整結果，並可與轉錄體與單細胞分析結果交叉對照。

1. 完成 Bulk RNA-seq 分析平台之核心模組，穩定產出差異表達基因、基因共表達模組、Hub genes 與生物途徑富集分析結果。
2. 擴充 scRNA-seq 分析平台，完成細胞分群、細胞類型註解、細胞比例摘要與細胞型特異性表現特徵之平台化輸出。
3. 建立 WES、Bulk RNA-seq 與 scRNA-seq 平台之一致化資料結構與整合接口，使遺傳、基因表現與細胞層級證據可跨平台整併與一致管理。

第三年預期完成項目：多體學分析平台定型與蛋白質體平台建置

1. 於上半年完成 WES 分析平台之最終定型，形成可長期維運、可重現且可審計之 Exome-wide 分析平台，並正式納入整體多體學證據產出流程。
2. 完成 Bulk RNA-seq 與 scRNA-seq 平台之進階分析模組，包含共表達網絡深化、細胞狀態轉換（Pseudotime）與細胞間通訊分析，使平台具備完整疾病情境解析能力。
3. 建置蛋白質體（Proteomics）分析平台之核心流程，完成蛋白質鑑定、定量、差異表達分析與初步 PPI 網路建構，產出蛋白層級之結構化證據資料。
4. 建立跨體學一致性檢核機制，使遺傳、轉錄體、單細胞與蛋白質體分析結果可系統性比對與整合。

第四年預期完成項目：蛋白質體平台深化與整合式 AI 平台成果輸出

1. 完成蛋白質體分析平台之深化建置，穩定產出差異蛋白清單、蛋白質交互作用網路、功能模組與 Hub proteins 優先排序結果，形成高轉譯潛力之蛋白層證據。
2. 完成多體學分析平台（平台一至六）之全面整合，將結構化證據納入單一可擴充之系統架構中。
3. 建置並完成整合式 AI 藥物開發平台，串聯多體學分析平台與子計畫 2 至 4 之 AI 推論模組，提供端到端之標靶—藥物評估與決策流程。
4. 產出具疾病情境導向之標靶與藥物優先排序結果、轉譯風險評估與完整可追溯之 AI 推論與決策紀錄，作為後續實驗驗證、藥物優化與臨床轉譯之依據。

子計畫 2：疾病、標靶與藥物生物證據之推論與信心決策模組

第一年預期完成項目：基因體證據調用流程與標靶信心評分雛型建立

1. 完成生物資訊與統計分析子代理人（A1）之證據檢索 API 工具模組化實作，建立可重複調用之基因體層級證據取得機制。
2. 建置（**A1**）**基於 SNP 分析結果**之工具模組調用流程，使系統可依 GWAS 與相關統計結果自動擷取與整理標靶候選證據。
3. 建置（**A1**）**基於 WES 分析結果**之工具模組調用流程，使外顯子變異層級之標靶關聯證據可納入整體分析 pipeline。
4. 完成標靶證據解讀與信心評分子代理人（A2）之初版設計與實作，建立基於「（A1）：基因體層級表型關聯結果」的資料彙整、權重整合與信心評分流程。
5. 完成年度研究成果之技術報告與學術論文撰寫。

第二年預期完成項目：藥物與藥理證據整合推論流程建置

1. 完成藥理學與藥物化學證據檢索子代理人（A3）之 PubMed 與 DrugBank 檢索 API 工具模組化與調用流程實作，建立文獻與藥物資料之自動化蒐集能力。

2. 完成藥物–標靶證據解讀與推論專家子代理人（A4）之設計與實作，建立基於「（A3）：藥物資料庫檢索與彙整結果」的資料整合、評分與推論流程。
3. 建置主代理人（Orchestrator）調用各子代理人之整體流程，使系統可整合分析藥物–標靶–疾病治療潛力與不確定性。
4. 完成年度研究成果之技術報告與學術論文撰寫。

第三年預期完成項目：跨體學證據調用流程擴充與藥物化學建模能力強化

1. 設計生物資訊與統計分析子代理人（A1）基於單細胞定序、轉錄體定序與蛋白體之「標靶—臨床表型資料」調用證據之整體流程架構。
2. 完成（**A1**）**基於單細胞 RNA 定序資料**之工具模組調用流程設計，使細胞型特異之標靶證據可被系統化整合。
3. 完成（**A1**）**基於轉錄體定序資料**之工具模組調用流程設計，使基因表現與臨床表型關聯證據可納入分析。
4. 完成（**A1**）**基於蛋白體之標靶—臨床表型資料**之工具模組調用流程設計，支援蛋白層級之標靶功能證據整合。
5. 完成藥理學與藥物化學證據建模子代理人（A3）之 CheMBL 檢索 API 工具模組化與調用流程實作，擴充藥物結構與活性資料之建模能力。
6. 完成年度研究成果之技術報告與學術論文撰寫。

第四年預期完成項目：多體學證據整合定型與系統效能優化

1. 完成生物資訊與統計分析子代理人（A1）基於單細胞定序、轉錄體定序與蛋白體之「標靶—臨床表型資料」之完整調用流程設計與實作。
2. 完成（**A1**）**基於單細胞 RNA 定序資料**之工具模組調用流程實作，使細胞層級證據可穩定納入決策流程。
3. 完成（**A1**）**基於轉錄體定序資料**之工具模組調用流程實作，強化基因表現層級之證據整合能力。
4. 完成（**A1**）**基於蛋白體之標靶—臨床表型資料**之工具模組調用流程實作，形成跨體學一致化之證據輸入 pipeline。
5. 完成標靶證據解讀與信心評分子代理人（A2）之進階版本，建立基於「（A1）：單細胞定序、轉錄體定序與蛋白體資料」之整合彙整與信心評分流程。
6. 利用本地臨床資料微調與校正子代理人，以提升整體系統之推論穩定性與實務適用性。
7. 完成整體研究成果之技術報告與學術論文撰寫。

<u>子計畫 3： AI 藥物設計與最佳化 - 以 PAI-1 之胜肽先導分子為主案例</u>

第一年預期完成項目：Designer Agent 基準流程與候選生成雛型建立

1. 建立可實際執行之 **Designer Agent baseline 設計流程**，完成與子計畫 2 生醫目標（2A）–（2D）之資料匯入介面，並確立固定欄位、可追溯來源與證據可驗證之資料結構。
2. 完成胜肽/蛋白質設計路徑之**結構建模與基準評分流程**，包含先導分子之 FASTA/SMILES 表示、PDB/SDF 結構生成、以及 Docking 與能量評分之自動化 Pipeline。
3. 以示範標靶 PAI-1 為案例，產生至少數百個候選變體，並完成結合相關指標（例如：ΔG/K_d）與 ADMET/免疫原性之初步排序，形成可送入子計畫 4 之候選分子套件雛型。
4. 建立可修飾位置清單（Modifiable Sites List）與互作指紋（PLIF）之標準化輸出格式，作為後續動態最佳化掃描與設計約束之基礎。

5. 完成端到端計算流程之效能與能耗基準量測，作為後續導入高效率 Attention 方法（PSOS）之前的比較依據。

第二年預期完成項目：親和力/選擇性最佳化與可解釋設計流程完成

1. 完成**親和力與選擇性最佳化模組**，使候選分子在結合相關指標上相較先導分子具有明確改善，並能對應至特定 MOA（如抑制或中和）之結構假設。
2. 建立可解釋設計輸出機制，包含 Attention map、SHAP 3D heatmap 與結構層級之作用熱點視覺化，使設計理由可被驗證並支援下游臨床推論假設設定。
3. 辨識長序列與大量候選情境下之主要計算瓶頸，並於必要模組中導入 **PSOS（Prefix-Scan Online Softmax）**原型實作，在維持 FP32 精度前提下，顯著降低推論延遲與資源消耗。
4. 形成可重複執行之動態最佳化掃描流程（Dynamic Optimization Scan），使 Designer Agent 能在有限計算預算下，快速收斂至少量高潛力候選。

第三年預期完成項目：多參數去風險與 PBPK/QSP 回饋驅動之迭代設計

1. 完成**多參數去風險設計流程**，整合 ADMET、毒性（含 Tox21）、免疫原性（NetMHCpan）與合成可行性等指標，形成一致尺度與不確定性評估機制。
2. 建立子計畫 3（Designer Agent）與子計畫 4（Clinical Reasoning Agent）之**結構化回饋介面**，使 PBPK/QSP 推論結果可量化回寫至設計端，成為候選更新之驅動訊號。
3. 以示範標靶 PAI-1 完成至少數輪「設計→臨床推論→回饋→更新」之閉迴路迭代，產出在結合、可開發性與臨床推論條件上均衡之候選集合。
4. 將設計結果轉譯為可操作之實驗優先順序與量測建議，支援 SPR、細胞與動物實驗之資源配置與去風險決策。

第四年預期完成項目：端到端整合示範與 Designer Agent 平台化部署

1. 完成 **Designer Agent 之平台化整合與部署**，以 k3s 與 n8n 建立可重複執行、可監控且可維運之設計流程，並與子計畫 2 至 4 形成端到端系統。
2. 以胰臟癌 PAI-1 案例完成完整示範，輸出可供前臨床評估之候選分子清單與可驗證決策報告，內容包含結構、評分、去風險摘要與 MOA 假設。
3. 建立平台化部署文件、資料格式規格與效能/能耗基準報告，使 Designer Agent 可移植至其他癌別或標靶情境。
4. 驗證 PSOS 等高效率 Attention 方法於實際藥物設計流程中的工程效益，證明其作為高精度 AI 藥物最佳化平台之關鍵支援技術。

<u>子計畫 4：AI 驅動之虛擬臨床試驗評估與決策中樞</u>

第一年預期完成項目：生理藥動學代理建置與 PBPK 平台整合

1. 建立並完成 **PBPK 自動化模擬平台**，整合 PK-Sim®之批次模擬流程，形成可重複執行、可追蹤之藥動學推估 pipeline，支援不同候選分子與物種條件之快速模擬。
2. 完成**生理藥動學子代理（Sub-agent 1）**之建置與參數校準，**利用 NCKU PAI-1 臨床試驗數據進行在地化參數修正**，使其可準確預測 PAI-1 抑制劑於小鼠與人類體內之 PK 曲線。
3. 建立 **ADMET-AI 本地端推論服務**與 **FDA/TFDA 法規資料庫自動化檢索系統**，產出首批候選分子之毒性、藥物動力學風險評估與法規對照數據，作為後續設計與臨床推論之基礎輸入。
4. 形成穩定之「候選分子（子計畫 3）→ PBPK 模擬→ PK 預測」資料流，奠定後續藥效與臨床推論子計畫整合之基礎。

第二年預期完成項目：系統藥理學代理建置與 QSP 推論能力完成

1. 完成 **QSP 自動化模擬介面**，將 MoBi®系統藥理模型參數化，建立藥物結合特性與下游訊號抑制效果之定量對應關係。
2. 建置並完成**系統藥理學子代理（Sub-agent 2）**，使其能學習並模擬 PAI-1/LRP1 下游關鍵路徑（如 p-Smad2/3 與纖維化相關路徑）之動態反應。
3. 完成 **PK–PD 連動模型（PK–PD Link Model）**，開發 **PK-PD Linker 中間件**，使藥物暴露量、受體佔有率（RO%）與路徑抑制效果可於同一框架下整合推論。
4. 建立 Sub-agent 1（PK）與 Sub-agent 2（PD）之 **標準化資料交換協定（JSON）**與穩定串接機制，使候選分子之藥動與藥效推論可於系統層級連續運作。

第三年預期完成項目：因果分層代理建置與虛擬臨床族群建立

1. 建立並完成**因果分層子代理（Sub-agent 3）**，整合本地臨床與多體學資料，利用因果森林（Causal Forest）等方法辨識高反應族群之關鍵特徵。
2. 完成**胰臟癌虛擬臨床族群（Virtual Cohort）**之建置，深度整合成大醫院 **RWD 臨床資料**、在地多體學資料與 TCGA 公開資料 [40]，形成具台灣亞裔特徵之數位病患集合。
3. 在尚未導入 Orchestrator 自主決策的情況下，完成 Sub-agent 1（PK）、Sub-agent 2（PD）與 Sub-agent 3（Causal）之**硬編碼（Hard-coded）端到端資料串接與聯合測試**。
4. 產出第一批虛擬臨床試驗資料，包含個體化治療效應評分（ITE Score）與族群層級反應分布，建立完整但尚未自動決策的虛擬試驗資料鏈。
5. 完成臨床專家決策流程的資料收集（Expert Trajectories），將其轉化為訓練數據集，正式啟動 Orchestrator 之**監督式強化學習（SRL）**訓練。

第四年預期完成項目：Orchestrator 完成與 AI 驅動虛擬臨床試驗平台驗證

1. 優化並完成 **Orchestrator 與臨床推理模型**之建置與微調（使用自行改良之 SRL），學習 **NCKU 專家黃金標準**，並整合 FDA/TFDA 指引、臨床試驗設計規範與 PAI-1 領域知識，使系統能綜合多子代理決策結果。
2. 建立具備「**思考鏈（Chain-of-Thought）**」與**可解釋推論日誌（Reasoning Logs）**的 AI-driven 虛擬臨床試驗框架，能自主產出包含引用來源之收案條件、劑量建議、風險評估與轉譯決策報告。
3. 完成「**虛擬臨床試驗 vs. 真實世界數據（Sim vs. Real）**」之交叉驗證，確認系統預測之存活曲線與歷史臨床資料具高度一致性。
4. 產出具專家認可水準之**轉譯決策報告（Translational Decision Report）**，證明平台所生成之臨床試驗設計建議具備 IND 申請前評估之科學可信度。

二、 對於參與之工作人員，預期可獲之訓練

本計畫為一結合臨床醫學、生物資訊、人工智慧與藥物研發之高度跨領域整合型計畫，參與之工作人員將可在計畫執行過程中，獲得系統性且具實務價值之專業訓練。

首先，在資料與分析層面，研究人員將接受臨床真實世界資料（Real-World Data, RWD）與多體學資料（GWAS、WES、scRNA-seq、RNA-seq、Proteomics）之標準化處理、品質控管與平台化分析訓練，熟悉如何將異質資料轉換為可供 AI 模型與決策系統使用之可計算證據（Computable evidence）。

其次，在人工智慧與系統層面，參與人員將深入學習多代理人（Multi-Agent）協作架構、工具調用（Toolformer-like）設計 [3]、可解釋推論（Confidence scoring、Reasoning logs）以及 Agent

orchestration 等關鍵技術，培養設計與實作具可追溯性與可驗證性 AI 系統之能力，這對未來 AI 醫療與藥物研發應用具高度前瞻性。

此外，在藥物研發與臨床轉譯層面，研究人員將實際參與候選藥物之結構優化、ADMET 去風險評估、PBPK/QSP 模擬與虛擬臨床試驗設計，理解藥物從早期設計到 pre-IND 決策之完整流程，培養能同時理解工程、藥理與臨床需求之跨界人才。

整體而言，本計畫將培養具備「資料—AI—臨床轉譯」整合能力之高階研究與工程人才，對於我國在 AI 精準醫療與新藥研發領域之長期人力培育具有重要意義。

三、 預期完成之研究成果（如實務應用績效、期刊論文、研討會論文、專書、技術報告、專利或技術移轉等質與量之預期成果）

本計畫之預期研究成果兼具**學術價值、工程實作成果與實務應用潛力**，可歸納如下：

（一）平台與實務應用成果

1. 建立一套以人類資料為核心之端到端 AI 新藥研發平台，涵蓋多體學證據整合、標靶與藥物信心決策、候選藥物設計，以及虛擬臨床試驗與轉譯決策支援。
2. 完成具可重複執行、可追溯與可維運之多代理人決策系統（Council of Agents），可實際應用於標靶評估、藥物優先排序與風險分層。
3. 產出可供 pre-IND 階段使用之虛擬臨床試驗分析結果，包括劑量建議、族群分層與安全性風險評估，具實質決策支援價值。

（二）學術研究成果

1. 預期於計畫執行期間，每年投稿數篇論文於國際期刊與頂尖國際研討會（例如：AI in Medicine、Bioinformatics、Machine Learning for Drug Discovery 等相關領域）。
2. 產出具原創性之方法論成果，包括多代理人決策推論架構、可解釋信心評分機制、PSOS 高效率演算法與臨床導向虛擬試驗方法。

（三）技術、智財與後續轉譯成果

1. 形成具專利潛力之核心技術（多代理協作決策方法、物理導向生成式設計、虛擬臨床試驗與數位孿生方法）。
2. 建立可作為後續技術移轉、產學合作或 SaaS 平台服務之技術基礎。
3. 為後續候選藥物授權、共同開發或新創公司孵化奠定可行之技術與資料基礎。

四、 學術研究、國家發展及其他應用方面預期之貢獻。

（一）對學術研究之貢獻

本計畫首創以「人類資料優先（Human-data-first）」為核心的端到端 AI 藥物研發研究架構，突破傳統 AI 藥物開發多聚焦於分子生成、單一模型預測或動物實驗導向評估之研究取向，系統性引入多體學證據、臨床資料與系統藥理模型，補足 AI 藥物研發在臨床轉譯可行性與決策可解釋性上的關鍵缺口。透過多代理人協作架構，本計畫將人類專家在標靶選擇、藥物設計與臨床評估中隱含的決策邏輯轉化為可追溯、可驗證且可重複執行之計算流程，為 AI 醫學研究提供一種兼顧資料驅動與專家知識的嶄新方法論。此一架構不僅可作為 AI 藥物研發研究之通用範式，亦有助於推動 AI 模型在高風險醫療決策場域中的可信度與實用性，對 AI 醫學、計算藥理與精準醫療等相關研究領域具有實質學術貢獻。

（二）對國家發展之貢獻

本計畫充分結合台灣在地臨床資料、醫療體系與跨領域研究能量，建立具族群特異性與臨床導向之 AI 藥物研發平台，有助於提升我國在精準醫療、智慧醫療與新藥研發領域之自主能力。透過以人類資料為核心的分析與決策流程，本計畫可降低對動物模型與外部

資料之依賴，強化國內生醫研究在真實世界情境下之應用價值，回應國家在高附加價值生醫產業與 AI 技術自主化之政策方向。長期而言，本計畫所建立之平台化能力與關鍵技術，將有助於提升我國在 AI 新藥研發與臨床轉譯領域之國際能見度與競爭力，並作為未來國家級精準醫療與生醫 AI 發展之重要基礎。

（三）對產業與社會應用之貢獻

本計畫所建構之 AI 藥物研發與虛擬臨床試驗平台，可作為國內外藥廠與生技公司於早期藥物研發與臨床前決策階段的重要支援工具，協助其在有限資源下進行標靶與候選藥物之有效篩選，降低研發風險與整體開發成本，並加速具潛力之創新藥物進入臨床試驗階段。在社會層面，透過提升新藥研發效率與成功率，將有助於改善癌症等高風險疾病之治療選擇，提升病患福祉與醫療體系效能。長期而言，本計畫亦有助於促成產學醫之深度合作，培育兼具 AI、藥物研發與臨床理解之跨領域人才，推動台灣發展成為亞太地區具影響力之 AI 新藥研發與臨床轉譯樞紐。

參考資料

[1] 衛服部統計處, “113 年國人死因統計結果”, https://www.mohw.gov.tw/cp-7177-82775-1.html

[2] 衛服部統計處, “死因統計/歷年統計”, https://dep.mohw.gov.tw/DOS/lp-5069-113.html

[3] Schick *et al.,* Toolformer: Language Models Can Teach Themselves to Use Tools. arXiv:2302.04761, 2023.

[4] Jin *et al.,* GeneGPT: Augmenting large language models with domain tools for improved access to biomedical information. Bioinformatics, 40(2), 2024, btae075. doi:10.1093/bioinformatics/btae075.

[5] Wang *et al.,* Pancreatic stellate cells activated by mutant KRAS-mediated PAI-1 upregulation foster pancreatic cancer progression via IL-8. Theranostics, 9(24), 7168–7183, 2019. doi:10.7150/thno.36830.

[6] Blackman *et al.,* NVIDIA Nemotron 3: Efficient and Open Intelligence. arXiv, 2025 (technical report / preprint).

[7] Mayr *et al.,* DeepTox: Toxicity prediction using deep learning. Frontiers in Environmental Science, 3:80, 2016. doi:10.3389/fenvs.2015.00080.

[8] Sun *et al.,* scDrug+: Predicting drug responses using single-cell transcriptomics and molecular structure. Biomedicine & Pharmacotherapy, 177, 117070, 2024.

[9] Deng, Y., *et al.* Supervised Reinforcement Learning: From Expert Trajectories to Step-wise Reasoning. International Conference on Learning Representations (ICLR), 2026 (to appear).

[10] Xu *et al.,* A generative AI-discovered TNIK inhibitor for idiopathic pulmonary fibrosis: a randomized phase 2a trial, Nature Medicine volume 31, 2602–2610, 2025

[11] Vichentijevikj *et al.,* Prompt-to-Pill: End-to-End Drug Discovery with Generative AI Agents. Bioinformatics Advances, 6(1), 2026, vbaf323.

[12] Boiko *et al.,* Emergent autonomous scientific research capabilities of large language models. Nature, 624, 570–578, 2023. doi:10.1038/s41586-023-06763-y.

[13] Lu *et al.,* The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery. arXiv:2408.06292, 2024 (preprint).

[14] Fisher *et al.,* Digital Twins for Clinical Trials: A Personalized Baseline Approach. Clinical Trials.

[15] Ren *et al.,* A Small-Molecule TNIK Inhibitor Targets Fibrosis in Preclinical and Clinical Models. Nature Biotechnology, 43(1), 63–75, 2024.

[16] Li *et al.,* OmicsNavigator: An LLM-driven multi-agent system for autonomous zero-shot biological analysis in spatial omics. bioRxiv (preprint).

[17] Lin *et al.,* GeneRAG: Enhancing Large Language Models with Gene-Related Task by Retrieval-Augmented Generation. bioRxiv (preprint).

[18] Gou *et al.,* ToolOrchestra: Connecting Large Language Models with Tools via Multi-Agent Collaboration. arXiv (preprint).

[19] Vaswani *et al.,* Attention Is All You Need. Advances in Neural Information Processing Systems (NeurIPS), 2017.

[20] Dosovitskiy *et al.,* An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations (ICLR), 2021.

[21] Dao *et al.,* FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. NeurIPS, 2022.

[22] Dao *et al.,* FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. International Conference on Learning Representations (ICLR), 2024.

[23] Jumper *et al.,* Highly accurate protein structure prediction with AlphaFold. Nature, 596(7873), 583–589, 2021.
[24] Lin *et al.,* Evolutionary-scale prediction of atomic-level protein structure with a language model. Science, 379(6637), 1123–1130, 2023.
[25] Trott *et al.,* AutoDock Vina: Improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. Journal of Computational Chemistry, 31(2), 455–461, 2010.
[26] Brooks *et al.,* CHARMM: A program for macromolecular energy, minimization, and dynamics calculations. Journal of Computational Chemistry, 4(2), 187–217, 1983.
[27] Vanommeslaeghe *et al.,* Automation of the CHARMM General Force Field (CGenFF) I: Bond perception and atom typing. Journal of Chemical Information and Modeling, 52(12), 3144–3154, 2012.
[28] Genheden *et al.,* AiZynthFinder: A fast, robust and flexible open-source software for retrosynthetic planning. Journal of Cheminformatics, 12, 70, 2020.
[29] Xiong *et al.,* ADMETlab 2.0: An integrated online platform for accurate and comprehensive predictions of ADMET properties. Nucleic Acids Research, 49(W1), W5–W14, 2021.
[30] Reynisson *et al.,* NetMHCpan-4.1 and NetMHCIIpan-4.0: Improved predictions of MHC antigen presentation. Nucleic Acids Research, 48(W1), W449–W454, 2020.
[31] Lundberg *et al.,* A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017.
[32] National Center for Advancing Translational Sciences (NCATS)*.,* Tox21 Data Challenge. 2014. https://tripod.nih.gov/tox21/challenge/.
[33] Landrum *et al.,* RDKit: Open-source cheminformatics. Zenodo.
[34] Viceconti *et al.,* In silico clinical trials: How computer simulation will transform the biomedical industry. International Journal of Clinical Trials, 3(2), 37–46, 2016.
[35] Wang *et al.,* Prompt-to-Pill: Multi-Agent Drug Discovery and Clinical Simulation Pipeline. bioRxiv (preprint).
[36] NVIDIA. *,* NVIDIA Nemotron-3-Nano Technical Report. NVIDIA Research.
[37] Eissing *et al.,* A computational systems biology software platform for multiscale modeling and simulation. Frontiers in Physiology, 2:4, 2011. doi:10.3389/fphys.2011.00004.
[38] Swanson *et al.,* ADMET-AI: A machine learning ADMET platform for evaluation of large-scale chemical libraries. Bioinformatics, 40(7), btae416, 2024. doi:10.1093/bioinformatics/btae416.
[39] Wittig *et al.,* SABIO-RK: An updated resource for manually curated biochemical reaction kinetics. Nucleic Acids Research, 46(D1), D656–D660.
[40] Cancer Genome Atlas Research Network*.,* The Cancer Genome Atlas Pan-Cancer analysis project. Nature Genetics, 45(10), 1113–1120.
[41] Zhang *et al.,* The International Cancer Genome Consortium Data Portal. Nature Biotechnology, 37(4), 367–369.
[42] Arafeh *et al.,* The present and future of the Cancer Dependency Map. Nature Reviews Cancer, 25(1), 59–73.
[43] Wishart *et al.,* DrugBank 5.0. Nucleic Acids Res, 46, D1074–D1082.
[44] Cunningham *et al.,* Ensembl 2022. Nucleic Acids Res, 50, D988–D995.
[45] Gaulton *et al.,* The ChEMBL database. Nucleic Acids Res, 45, D945–D954.

[46] Willmann *et al.,* PK-Sim®: A physiologically based pharmacokinetic whole-body model. BDD, 28, 319–334, 2007.
[47] Eissing *et al.,* A computational systems biology software platform. Front Physiol, 2, 4, 2011.
[48] Stuart *et al.,* Comprehensive Integration of Single-Cell Data. Cell, 177(7), 1888–1902.e21, 2019. doi:10.1016/j.cell.2019.05.031
[49] Purcell *et al.,* PLINK: A Tool Set for Whole-Genome Association and Population-Based Linkage Analyses. American Journal of Human Genetics, 81(3), 559–575, 2007. doi:10.1086/519795
[50] Love *et al.,* Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. Genome Biology, 15(12), 550, 2014.doi:10.1186/s13059-014-0550-8
[51] Cox, J., *et al. ,* MaxQuant enables high peptide identification rates, individualized p.p.b.-range mass accuracies and proteome-wide protein quantification. Nature Biotechnology, 26(12), 1367–1372, 2008. doi:10.1038/nbt.1511
[52] Bercovich *et al.,* Llama-Nemotron: Efficient Reasoning Models. *arXiv preprint* arXiv:2505.00949, 2025.